


Correlación



Introducción

Relaciones

Relaciones lineales

Relaciones positivas y negativas

Relaciones perfectas e imperfectas

Correlación

El coeficiente de correlación lineal r de Pearson

Otros coeficientes de correlación

Efecto del rango sobre la correlación

Efecto del puntaje extremo


La correlación no implica causalidad

¿CUÁL ES LA VERDAD? "Un buen director = una buena escuela" ¿O no es así?

Resumen

Términos importantes

Preguntas y problemas



INTRODUCCIÓN

En los capítulos anteriores nos ocupamos sobre todo de las distribuciones individuales y la mejor forma de caracterizarlas. Además de describir estas distribuciones, con frecuencia es necesario determinar si los datos de una distribución se relacionan con los datos de otra. Por ejemplo, la persona encargada del departamento de recursos humanos de una gran empresa podría estar muy interesada en saber si existe alguna relación entre las calificaciones obtenidas en la universidad por los empleados y el éxito de éstos en la compañía. Si verdaderamente existe una relación fuerte entre estas dos variables, entonces las calificaciones obtenidas en la universidad se podrían usar para predecir el éxito en la empresa y, por lo tanto, serían muy útiles a la hora de seleccionar a los futuros empleados.

Además de la utilidad práctica que implica el uso de una relación para hacer predicciones, ¿por qué podría interesarnos saber si dos variables están relacionadas entre sí? Una razón importante de esto es que si las variables están relacionadas, es posible que una de ellas sea la causa de la otra.* Como veremos más adelante en este capítulo, el hecho de que dos variables estén relacionadas entre sí no es una base suficiente para demostrar la causalidad. Sin embargo, como los estudios de correlación son de los más fáciles de realizar, demostrar que existe una correlación entre las variables es con frecuencia el primer paso para demostrar que existe una relación causal entre ellas. Recíprocamente, si no existe correlación alguna entre las dos variables, entonces se puede descartar la idea de que exista una relación causal.

Otro uso muy importante de la correlación es la determinación de la “confiabilidad test-retest” de los instrumentos de prueba. La confiabilidad test-retest significa que existe consistencia en los puntajes obtenidos en aplicaciones repetidas de la prueba. Por ejemplo, suponiendo que el CI de un individuo permanezca estable de un mes a otro, esperaríamos que una buena prueba de CI mostrara una relación fuerte entre los puntajes obtenidos por el mismo individuo en dos administraciones de la prueba, realizadas con un mes de diferencia. Las técnicas correlacionales nos permiten cuantificar la relación entre los puntajes obtenidos en las dos aplicaciones y, de esta manera, medir la confiabilidad test-retest del instrumento.

La correlación y la regresión están muy relacionadas entre sí. Ambas implican la relación entre dos o más variables. La correlación sirve principalmente para averiguar si existe una relación y para determinar su magnitud y dirección, mientras que la regresión se refiere principalmente al hecho de utilizar la relación para hacer una predicción. En este capítulo analizaremos la correlación y en el capítulo 7 abordaremos el tema de la regresión lineal.



RELACIONES

La correlación se ocupa de establecer la magnitud y la dirección de las relaciones. Antes de profundizar en estos aspectos particulares de las relaciones, analizaremos algunas características generales de éstas, mediante las cuales podremos comprender mejor el material específico acerca de la correlación.

Relaciones lineales

Para iniciar nuestra exposición de las relaciones, veamos como ilustración una relación lineal entre dos variables. La tabla 6.1 muestra el salario mensual de cinco agentes de ventas y el valor en dólares de la mercancía vendida por cada uno de ellos en ese mes.

Podremos percibir mejor la relación entre estas variables si utilizamos los pares de valores X y Y que corresponden a cada agente de ventas, como los puntos para trazar una gráfica. La gráfica así obtenida se llama gráfica de *dispersión* o *dispersigrama*

definición ■ Una gráfica de **dispersión** o **dispersigrama** es una gráfica de pares de valores X y Y .

* Reconocemos que el tema de la causa y el efecto ha dado lugar a muchos debates filosóficos. Sin embargo, no podemos analizar todos los aspectos relacionados con ese tema. Al emplear el término causa, lo hacemos en la acepción de uso común que entienden quienes no son filósofos. Es decir, cuando decimos que A es la causa de B , queremos decir que una variación en A produjo una variación en B , estando controladas todas las demás variables en forma adecuada.

tabla 6.1 Salarios y mercancía vendida

Agente de ventas	Variable X mercancía vendida (\$)	Variable Y salario (\$)
1	0	500
2	1000	900
3	2000	1300
4	3000	1700
5	4000	2100

La gráfica de dispersión para los datos de los agentes de ventas aparece en la figura 6.1. En relación con esta figura, vemos que todos los puntos están sobre una línea recta. Cuando una línea recta describe la relación entre dos variables, se dice que esta relación es *lineal*.

definición ■ Una **relación lineal** entre dos variables es la que puede representarse con mayor exactitud por medio de una línea recta.

Observe que no todas las relaciones son lineales; algunas de ellas son *curvilíneas*. En esos casos, al trazar una gráfica de dispersión para las variables X y Y , una línea *curva* se ajusta mejor a los datos que una recta.

Obtención de la ecuación de la línea recta La relación entre “salario” y “mercancía vendida” que aparece en la figura 6.1 se puede describir por medio de una ecuación. Por




figura 6.1 Gráfica de la relación entre el salario y la mercancía vendida.

supuesto, esa ecuación es la que corresponde a la línea que une todos los puntos. La forma general de la ecuación está dada por

$$Y = bX + a \quad \text{ecuación de una línea recta}$$

donde $a = Y$ ordenada al origen (el valor de Y cuando $X = 0$)

$b =$ pendiente de la recta

Determinación de la Y ordenada al origen a La Y ordenada al origen es el valor de Y cuando la recta corta al eje vertical. Así pues, es el valor de Y cuando $X = 0$. Para este problema, podemos ver en la figura 6.1 que:

$$a = Y \text{ ordenada al origen} = 500$$

Determinación de la pendiente b La pendiente de una recta es una medida de su razón de cambio. Nos dice cuánto cambia un dato Y por cada cambio unitario en el dato X . Expresado como una ecuación:

$$b = \text{pendiente} = \frac{\Delta Y}{\Delta X} = \frac{Y_2 - Y_1}{X_2 - X_1} \quad \text{pendiente de una línea recta}$$

Como estamos trabajando con una línea recta, la pendiente es constante. Esto significa que no importa qué valores elijamos para X_2 y X_1 , los datos correspondientes de Y_2 y Y_1 , siempre resultarán en el mismo valor para la pendiente. Para calcular la pendiente hagamos variar X de 2000 a 3000. Si $X_1 = 2000$, entonces $Y_1 = 1300$. Si $X_2 = 3000$, entonces $Y_2 = 1700$. Sustituyendo estos valores en la ecuación de la pendiente:

$$b = \text{pendiente} = \frac{\Delta Y}{\Delta X} = \frac{Y_2 - Y_1}{X_2 - X_1} = \frac{1700 - 1300}{3000 - 2000} = \frac{400}{1000} = 0.40$$

Así, la pendiente es 0.40. Esto significa que el valor Y aumenta 0.40 de unidad por cada incremento unitario en X . Esta forma de determinar la pendiente y la ordenada al origen se muestra también en la figura 6.2. Observe que obtendríamos la misma pendiente




figura 6.2 Gráfica del salario y la cantidad de mercancía vendida.

si escogiéramos otros valores para X_1 y X_2 . Por ejemplo, si $X_1 = 1000$ y $X_2 = 4000$, entonces $Y_1 = 900$ y $Y_2 = 2100$. Al despejar la pendiente se obtiene:

$$b = \text{pendiente} = \frac{\Delta Y}{\Delta X} = \frac{Y_2 - Y_1}{X_2 - X_1} = \frac{2100 - 900}{4000 - 1000} = \frac{1200}{3000} = 0.40$$

Una vez más, la pendiente es 0.40.

Ahora podemos escribir la ecuación completa para la relación lineal que existe entre el salario y la mercancía vendida:

$$Y = bX + a$$

Al sustituir los valores de a y b , tenemos que:

$$Y = 0.40X + 500$$

La ecuación $Y = 0.40X + 500$ describe la relación entre la variable Y (salario) y la variable X (mercancía vendida). Nos dice que Y incrementa 0.40 por cada unidad de incremento en X . Además, mientras la relación se conserve, esta ecuación nos permite calcular un valor apropiado para Y , para cualquier valor de X dado. Esto hace que la ecuación sea muy útil para hacer predicciones.

Predicción de Y cuando X se conoce Cuando se utiliza para hacer una predicción, la ecuación se vuelve:

$$Y' = 0.40X + 500$$

donde Y' = a la predicción del valor de la variable Y

Con esta ecuación podemos predecir cualquier valor de Y si sólo conocemos el valor X . Por ejemplo, si $X = 1500$ como en nuestro problema anterior, entonces:

$$\begin{aligned} Y' &= 0.40X + 500 \\ &= 0.40(1500) + 500 \\ &= 600 + 500 \\ &= 1100 \end{aligned}$$

Así, si un agente vende \$1500 de mercancía, su salario será igual a \$1100.

Por supuesto, también podríamos haber hecho la predicción de manera gráfica, como se muestra en la figura 6.1. Al proyectar en forma vertical el valor X de \$1500 hasta que corte la línea recta, podemos leer el valor predicho de Y en el eje vertical. La predicción de ese valor es \$1100, que es el mismo valor que obtenemos utilizando la ecuación.

Relaciones positivas y negativas

Además de ser lineal o curvilínea, una relación entre dos variables puede ser *positiva* o *negativa*.

definición ■ Una **relación positiva** indica que existe una relación directa entre las variables. Una **relación negativa** existe cuando hay una relación inversa entre X y Y .

La pendiente de la recta indica si la relación es positiva o negativa. Cuando la relación es positiva, la pendiente es positiva. En el ejemplo anterior se presentó una pendiente positiva; es decir, los valores altos de X están asociados con los valores altos de Y , y los valores bajos de X están asociados con los valores bajos de Y . Cuando la pendiente es positiva, la recta asciende cuando uno la recorre de izquierda a derecha, lo cual indica que al aumentar X , aumenta también Y . En consecuencia, existe una relación directa entre las dos variables.

Cuando la relación es negativa, existe una relación inversa entre las variables, lo cual hace que la pendiente sea negativa. La figura 6.3 muestra un ejemplo de una relación negativa. Observe que cuando la pendiente es negativa, la curva “desciende” cuando es recorrida de izquierda a derecha. Los valores bajos de X están asociados con valores altos de Y , mientras que los valores altos de X se relacionan con valores bajos de Y . Esto se puede expresar también diciendo que: a medida que X crece, Y decrece.

Relaciones perfectas e imperfectas

En las relaciones que hemos graficado hasta este momento, todos los puntos están sobre la línea recta. Cuando esto ocurre, la relación es *perfecta*. Por desgracia, las relaciones perfectas son escasas en las ciencias del comportamiento. Lo más común es encontrar relaciones imperfectas.

definición ■ Una **relación perfecta** es aquella en la cual existe una relación positiva o negativa para la cual todos los puntos se localizan sobre la recta. Una **relación imperfecta** es aquella en la cual existe una relación, pero no todos los puntos se localizan sobre la recta.




figura 6.3 Ejemplo de relación negativa.

tabla 6.2 CI y promedios de calificaciones de 12 estudiantes universitarios

Estudiante núm.	CI	Promedio de calificaciones
1	110	1.0
2	112	1.6
3	118	1.2
4	119	2.1
5	122	2.6
6	125	1.8
7	127	2.6
8	130	2.0
9	132	3.2
10	134	2.6
11	136	3.0
12	138	3.6

Por ejemplo, la tabla 6.2 muestra los puntos del CI y los promedios de calificaciones de una muestra de 12 estudiantes universitarios. Suponga que queríamos determinar si existe alguna relación entre estos datos hipotéticos. La gráfica de dispersión se presenta en la figura 6.4. Según la gráfica, es obvio que la relación entre el CI y las calificaciones escolares es imperfecta. La relación imperfecta es positiva, pues los valores bajos del CI




figura 6.4 Gráfica de dispersión del CI y del promedio de calificaciones.




figura 6.5 Gráfica de dispersión de la habilidad para la lectura y la cantidad de tiempo que miran la televisión unos alumnos de sexto grado.

están asociados con valores bajos de las calificaciones y los valores altos del CI están asociados con valores altos de las calificaciones. Además, la relación parece ser lineal.

La mejor manera de describir esta relación por medio de una recta es trazar la línea recta que se ajuste mejor a los datos. En otras palabras, cuando la relación es imperfecta, no es posible trazar una sola línea recta que pase por todos los puntos. Sin embargo, sí podemos hacer la línea recta que mejor se ajuste a los datos.* Hemos trazado esta recta en la figura 6.4. Esta recta de mejor ajuste se usa frecuentemente con propósitos de predicción; cuando se utiliza de esta manera se llama línea de *regresión*.

Un artículo reciente de *USA Today* informó que existe una relación inversa entre la cantidad de tiempo que los alumnos de nivel primario dedican a mirar la televisión y su habilidad para la lectura. Suponga que los datos del artículo sobre los estudiantes de sexto grado aparecieron tal como se presentan en la figura 6.5. Éste es un ejemplo de una relación lineal negativa e imperfecta. La relación es negativa, ya que los valores altos de observación de la televisión están asociados con valores bajos de habilidad para la lectura, y los valores bajos de observación de la televisión están asociados con valores altos de habilidad para la lectura. La relación lineal es imperfecta porque no todos los puntos se localizan sobre una sola línea recta. La línea de regresión para estos datos se muestra también en la figura 6.5.

Una vez concluida nuestra exposición de los fundamentos de las relaciones, ya podemos pasar al tema de la correlación.

*Los detalles acerca de la realización de esta recta serán analizados en el capítulo 7.



CORRELACIÓN

La correlación es un tema que se centra en la *dirección* y el *grado* de la relación. La dirección de la relación se refiere a si ésta es positiva o negativa. El grado de la relación se refiere a su magnitud o fuerza. El grado de la relación puede variar entre inexistente y perfecto. Cuando la relación es perfecta, la correlación es máxima y podemos predecir con exactitud una variable a partir de la otra. En esta situación, cuando X cambia también Y presenta un cambio. Además, el mismo valor de X siempre conduce al mismo valor de Y . En forma alternativa, el mismo valor de Y siempre conduce al mismo valor de X . Todos los puntos están sobre una línea recta si la relación es lineal. Cuando la relación es inexistente, la correlación alcanza su mínimo, y el hecho de conocer el valor de una de las variables no ayuda en nada a predecir el valor de la otra. Las relaciones imperfectas tienen niveles intermedios de correlación y la predicción es aproximada. En este caso, el mismo valor de X no siempre conduce al mismo valor de Y . Sin embargo, en promedio, Y cambia de manera sistemática con X , y podemos lograr una predicción mejor de Y si conocemos el valor de X que si no lo conocemos.

Aunque para ciertos fines basta hablar, de manera vaga, de correlaciones “altas” o “bajas”, con bastante frecuencia es recomendable conocer la magnitud y dirección exactas de la correlación. Un *coeficiente de correlación* nos proporciona esta información.

definición ■ *Un coeficiente de correlación expresa de manera cuantitativa la magnitud y dirección de una relación.*

Un coeficiente de correlación puede variar de $+1$ a -1 . El *signo* del coeficiente nos indica si la relación es *positiva* o *negativa*. La parte numérica del coeficiente de correlación describe la magnitud de la correlación. Mientras mayor sea el número, mayor será la correlación. Como 1 es el mayor número posible, éste representa una correlación perfecta. Un coeficiente de correlación de $+1$ significa que la correlación es perfecta y que la relación es positiva. Un coeficiente de correlación de -1 significa que la correlación es perfecta y que la relación es negativa. Cuando la relación es inexistente, el coeficiente de correlación es igual a 0. Las relaciones imperfectas tienen coeficientes de correlación cuya magnitud varía entre 0 y 1. Tendrán el signo menos o más según sea la dirección de la relación.

La figura 6.6 muestra las gráficas de dispersión de varias relaciones lineales distintas y los coeficientes de correlación de cada una de ellas. Utilizamos el coeficiente de correlación r de Pearson, pues las relaciones son lineales. Analizaremos la r de Pearson en la siguiente sección. Cada gráfica de dispersión está formada por parejas de valores X y Y . Observe que si los puntos están más cerca de la línea de regresión, la magnitud del coeficiente de correlación será mayor y la predicción será más exacta. Además, cuando la correlación es 0, no existe relación entre X y Y . Esto significa que Y no crece ni decrece de manera sistemática cuando X aumenta o disminuye. Así, en el caso de la correlación cero, la recta de regresión para predecir Y es horizontal, y el conocimiento de X no nos ayuda a conocer el valor de Y .




figura 6.6 Gráficas de dispersión de varias relaciones lineales.

El coeficiente de correlación lineal r de Pearson

Usted recordará, como se mencionó en el capítulo 5, que un problema básico para determinar la relación entre dos variables consiste en que, con mucha frecuencia, las variables han sido medidas en escalas y unidades diferentes. Por ejemplo, si nos interesa medir la correlación entre el CI y el promedio de calificaciones para los datos de la tabla 6.2, nos enfrentaríamos al problema de que ambos tienen escalas muy diferentes. Como mencionamos en el capítulo 5, podemos resolver esta dificultad al convertir cada calificación en su valor z transformado, lo cual colocaría a ambas variables en la misma escala, la escala z .

Para apreciar la utilidad de los puntajes z en la determinación de la correlación, consideremos el siguiente ejemplo. Suponga que el supermercado de su barrio tiene en venta naranjas empacadas; cada bolsa tiene marcado el precio total. Usted quiere saber si existe una relación entre el peso de las naranjas de cada bolsa y su costo. Como usted es un investigador nato, elige al azar seis bolsas y pesa cada una de ellas. El costo y el peso en libras de las seis bolsas aparecen en la tabla 6.3. La figura 6.7 muestra una gráfica de dispersión de los datos. ¿Están relacionadas estas dos variables? Sí; de hecho, todos los puntos están sobre una línea recta. Existe una correlación positiva perfecta entre el costo y el peso de las naranjas. Así, el coeficiente de correlación debe ser igual a $+1$.

Ahora veremos lo que ocurre al convertir estos datos en bruto en puntajes z . Los datos en bruto para el peso (X) y el costo (Y) están expresados como puntajes estándar en la cuarta y quinta columnas de la tabla 6.3. Ha ocurrido algo muy interesante: *las parejas de los datos en bruto para cada bolsa de naranjas tienen el mismo valor z* . Por ejemplo, las parejas de los datos en bruto para la bolsa A son 2.25 y 0.75. Sin embargo, sus

tabla 6.3 Costo y peso en libras de las seis bolsas de naranjas

Bolsa	Peso (libras) X	Costo (\$) Y	z_X	z_Y
A	2.25	0.75	-1.34	-1.34
B	3.00	1.00	-0.80	-0.80
C	3.75	1.25	-0.27	0.27
D	4.50	1.50	0.27	0.27
E	5.25	1.75	0.80	0.80
F	6.00	2.00	1.34	1.34

puntajes z respectivos son iguales a -1.34 . El dato en bruto de 2.25 está a tantas unidades de desviación estándar por debajo de la media de la distribución X como el dato en bruto de 0.75 está por debajo de la media de la distribución Y . Lo mismo es cierto para los otros pares de datos. Todos los pares de datos en bruto ocupan la misma posición relativa dentro de sus propias distribuciones. Es decir, tienen los mismos valores z . Al utilizar los datos en bruto, esta relación se oscurece debido a las diferencias de escala entre las dos variables. Si las parejas de datos ocupan la misma posición relativa dentro de sus propias distribuciones, entonces la correlación debe ser perfecta ($r = 1$) pues el hecho de conocer uno de los valores de la pareja de datos nos permite predecir de manera exacta al otro valor. Si la predicción es perfecta, la relación debe ser perfecta.

Esto nos lleva a la definición de la r de Pearson.

definición ■ *La r de Pearson es una medida del grado en el cual las parejas de datos ocupan posiciones iguales u opuestas dentro de sus propias distribuciones.*

Observe que esta definición también incluye a las parejas de datos que ocupan posiciones opuestas. Si las parejas de puntajes z tienen la misma magnitud, pero signos opuestos, la correlación sería perfecta de nuevo, y r sería igual a -1 .

Este ejemplo pone de relieve un aspecto muy importante. Como la correlación se refiere a la relación entre dos variables, y como es frecuente que las variables se midan en


**figura 6.7** Costo de naranjas contra su peso en libras.

tabla 6.4 Costo y peso en kilogramos de las seis bolsas de naranjas

Bolsa	Peso (kilogramos) X	Costo (\$) Y	z_X	z_Y
A	1.02	0.75	-1.34	-1.34
B	1.36	1.00	-0.80	-0.80
C	1.70	1.25	-0.27	-0.27
D	2.04	1.50	0.27	0.27
E	2.38	1.75	0.80	0.80
F	2.72	2.00	1.34	1.34

diferentes escalas y unidades, la magnitud y la dirección del coeficiente de correlación debe ser independiente de las diferencias de escalas y de unidades que existan entre las dos variables. La r de Pearson logra esto mediante los puntajes z . Así, podemos correlacionar variables tan diversas como la hora del día y la posición del Sol, el porcentaje de grasa contenido en el cuerpo y el consumo de calorías, la ansiedad ante un examen y la calificación obtenida, etcétera.

Como el presente es un aspecto muy importante, queremos ilustrarlo una vez más, al llevar el ejemplo anterior un paso más adelante. En el ejemplo sobre la relación entre el costo de las naranjas y su peso, suponga que usted pesó las naranjas en kilogramos y no en libras. ¿Deberá cambiar el grado de relación entre el costo y el peso de las naranjas a causa de esto? En vista de lo que acabamos de exponer, la respuesta es un no rotundo. La correlación debe ser independiente de las unidades utilizadas para medir las dos variables. Si la correlación entre el costo de las naranjas y su peso en libras es igual a 1, entonces la correlación entre el costo de las naranjas y su peso en kilogramos también debe ser 1. Hemos convertido el peso de cada bolsa de naranjas de libras a kilogramos. Los datos correspondientes aparecen en la tabla 6.4 y la gráfica de los datos en bruto se presenta en la figura 6.8. De nuevo, todos los datos se localizan sobre una línea recta, de modo que la correlación es igual a 1.00. Observe los valores de las parejas de puntajes z en la cuarta y quinta columnas de la tabla 6.4. De nuevo se presentan los mismos valores, que son los mismos que cuando el peso de las naranjas fue expresado en libras. Así, el uso de los puntajes z permite medir la relación entre las dos variables, de manera independiente a las diferencias de escala y unidad empleadas para medir las variables.




figura 6.8 Costo de las naranjas contra su peso en kilogramos.

Cálculo de la r de Pearson La ecuación para calcular la r de Pearson mediante puntajes z es

$$r = \frac{\sum z_X z_Y}{N - 1}$$

donde $\sum z_X z_Y$ es la suma de los productos de cada pareja de puntajes z

Para utilizar esta ecuación, primero hay que convertir cada dato en bruto en su valor z transformado. Esto puede ser muy tardado y da lugar a posibles errores de redondeo. Con un poco de álgebra, esta ecuación se puede transformar en una ecuación para hacer cálculos utilizando los datos en bruto:

$$r = \frac{\sum XY - \frac{(\sum X)(\sum Y)}{N}}{\sqrt{\left[\sum X^2 - \frac{(\sum X)^2}{N}\right]\left[\sum Y^2 - \frac{(\sum Y)^2}{N}\right]}} \quad \text{ecuación para el cálculo de la } r \text{ de Pearson}$$

donde $\sum XY$ es la suma de los productos de cada pareja X y Y ($\sum XY$ se llama también suma de productos cruzados).

Si desea encontrar una solución en la que se use la ecuación conceptual (puntajes z), busque Chapter 6 en el material adicional del libro, en: <http://www.thomsonlearning.com.mx>.

La tabla 6.5 contiene algunos datos hipotéticos obtenidos de cinco sujetos, ahora vamos a utilizar estos datos para calcular la r de Pearson:

$$r = \frac{\sum XY - \frac{(\sum X)(\sum Y)}{N}}{\sqrt{\left[\sum X^2 - \frac{(\sum X)^2}{N}\right]\left[\sum Y^2 - \frac{(\sum Y)^2}{N}\right]}}$$

tabla 6.5 Datos hipotéticos para el cálculo de la r de Pearson

Sujeto	X	Y	X^2	Y^2	XY
A	1	2	1	4	2
B	3	5	9	25	15
C	4	3	16	9	12
D	6	7	36	49	42
E	7	5	49	25	35
Total	21	22	111	112	106

$$\begin{aligned}
 r &= \frac{\sum XY - \frac{(\sum X)(\sum Y)}{N}}{\sqrt{\left[\sum X^2 - \frac{(\sum X)^2}{N}\right]\left[\sum Y^2 - \frac{(\sum Y)^2}{N}\right]}} \\
 &= \frac{106 - \frac{21(22)}{5}}{\sqrt{\left[111 - \frac{(21)^2}{5}\right]\left[112 - \frac{(22)^2}{5}\right]}} \\
 &= \frac{13.6}{18.616} = 0.731 = 0.73
 \end{aligned}$$

ΣXY es la suma de los productos cruzados. Se determina multiplicando los datos X y Y para cada sujeto y sumando a continuación los productos resultantes. El cálculo de ΣXY y de los otros términos aparece ilustrado en la tabla 6.5. Al sustituir estos valores en la ecuación anterior, obtenemos:

$$r = \frac{106 - \frac{21(22)}{5}}{\sqrt{\left[111 - \frac{(21)^2}{5}\right]\left[112 - \frac{(22)^2}{5}\right]}} = \frac{13.6}{\sqrt{22.8(15.2)}} = \frac{13.6}{18.616} = 0.731 \approx 0.73$$

Si desea encontrar una solución en la que se use la ecuación conceptual (puntajes z), busque Chapter 6 en el material adicional del libro, en: <http://www.thomsonlearning.com.mx>.



Probemos con otro ejercicio. Esta vez utilizaremos los datos de la tabla 6.2. Para su comodidad, hemos reproducido estos datos en las primeras tres columnas de la tabla acompañante. En este ejemplo tenemos una relación lineal imperfecta y nos interesa calcular la magnitud y la dirección de la relación mediante la r de Pearson. La solución también aparece en la tabla siguiente.

SOLUCIÓN

Estudiante núm.	CI X	Promedio de calificaciones	X^2	Y^2	XY
		Y			
1	110	1.0	12 100	1.00	110.0
2	112	1.6	12 544	2.56	179.2
3	118	1.2	13 924	1.44	141.6
4	119	2.1	14 161	4.41	249.9
5	122	2.6	14 884	6.76	317.2
6	125	1.8	15 625	3.24	225.0
7	127	2.6	16 129	6.76	330.2
8	130	2.0	16 900	4.00	260.0
9	132	3.2	17 424	10.24	422.4
10	134	2.6	17 956	6.76	348.4
11	136	3.0	18 496	9.00	408.0
12	138	3.6	19 044	12.96	496.8
Total	1503	27.3	189 187	69.13	3488.7

$$r = \frac{\Sigma XY - \frac{(\Sigma X)(\Sigma Y)}{N}}{\sqrt{\left[\Sigma X^2 - \frac{(\Sigma X)^2}{N}\right]\left[\Sigma Y^2 - \frac{(\Sigma Y)^2}{N}\right]}}$$

$$= \frac{3488.7 - \frac{1503(27.3)}{12}}{\sqrt{\left[189 187 - \frac{(1503)^2}{12}\right]\left[69.13 - \frac{(27.3)^2}{12}\right]}} = \frac{69.375}{81.088} = 0.856 \approx 0.86$$

Si desea encontrar una solución en la que se use la ecuación conceptual (puntajes z), busque Chapter 6 en el material adicional del libro, en: <http://www.thomsonlearning.com.mx>.

Tratemos de resolver otro problema. ¿Se ha puesto a reflexionar si es verdad que los opuestos se atraen? Todos hemos conocido alguna pareja formada por personas que parecen muy diferentes entre sí. Sin embargo, ¿es esto lo usual? ¿Qué es lo que fomenta la atracción: las diferencias o las similitudes?

Un psicólogo social que investigaba este problema pidió a 15 estudiantes que respondieran un cuestionario relacionado con sus actitudes hacia una amplia gama de temas. Tiempo después les mostró las “actitudes” de un desconocido hacia los mismos reactivos y les pidió que evaluaran su propio agrado o inclinación hacia dicho extraño y si consideraban probable que les resultara agradable trabajar con él. En realidad, las “actitudes” del desconocido habían sido inventadas por el experimentador y se variaron entre los individuos que participaron en el experimento, con respecto a la proporción de actitudes que cada uno compartía con el desconocido. De esta manera se obtuvieron datos para cada sujeto con respecto a sus actitudes y la atracción que sentía hacia el desconocido, con base en las actitudes de este último hacia los mismos reactivos. Si los iguales se atraen, entonces debe existir una relación directa entre la atracción que se siente hacia un desconocido y la proporción de actitudes que compartimos con él. Los datos se presentan en la tabla que aparece al final de este problema de práctica. Entre mayor sea la atracción, más alto será el puntaje. El máximo puntaje de atracción posible es 14. Calcule el coeficiente de correlación r de Pearson* para determinar si existe una relación directa entre la similitud de actitudes y el grado de atracción.

SOLUCIÓN

La solución aparece en la tabla siguiente.

Núm. de estudiante	Proporción de actitudes similares X	Atracción Y	X^2	Y^2	XY
1	0.30	8.9	0.090	79.21	2.670
2	0.44	9.3	0.194	86.49	4.092
3	0.67	9.6	0.449	92.16	6.432
4	0.00	6.2	0.000	38.44	0.000
5	0.50	8.8	0.250	77.44	4.400
6	0.15	8.1	0.022	65.61	1.215
7	0.58	9.5	0.336	90.25	5.510
8	0.32	7.1	0.102	50.41	2.272
9	0.72	11.0	0.518	121.00	7.920
10	1.00	11.7	1.000	136.89	11.700
11	0.87	11.5	0.757	132.25	10.005
12	0.09	7.3	0.008	53.29	0.657
13	0.82	10.0	0.672	100.00	8.200
14	0.64	10.0	0.410	100.00	6.400
15	0.24	7.5	0.058	56.25	1.800
Total	7.34	136.5	4.866	1279.69	73.273

*Como veremos en una sección posterior de este capítulo, el cálculo de la r de Pearson sólo es válido cuando los datos pertenecen a una escala de intervalo o de proporción. Por lo tanto, para calcular la r de Pearson en este problema, debemos suponer que los datos tienen al menos una escala de intervalo. (continúa)

$$\begin{aligned}
 r &= \frac{\sum XY - \frac{(\sum X)(\sum Y)}{N}}{\sqrt{\left[\sum X^2 - \frac{(\sum X)^2}{N} \right] \left[\sum Y^2 - \frac{(\sum Y)^2}{N} \right]}} \\
 &= \frac{73.273 - \frac{7.34(136.5)}{15}}{\sqrt{\left[4.866 - \frac{(7.34)^2}{15} \right] \left[1279.69 - \frac{(136.5)^2}{15} \right]}} \\
 &= \frac{6.479}{\sqrt{1.274(37.54)}} = \frac{6.479}{6.916} = 0.936 = 0.94
 \end{aligned}$$

Por lo tanto, tomando estos estudiantes como base, existe una relación muy fuerte entre las similitudes y la atracción.

Una segunda interpretación de la r de Pearson La r de Pearson se puede interpretar también en términos de la variabilidad de Y explicada por medio de X . Este punto de vista proporciona más información importante acerca de r y de la relación entre X y Y . Consideremos, por ejemplo, la figura 6.9, en la cual se muestra una relación imperfecta entre X y Y . En este ejemplo, la variable X representa el grado de destreza en ortografía, y la variable Y representa la habilidad en escritura de cada uno de seis estudiantes de tercer grado. Supongamos que se intenta predecir la calificación que obtendrá en escritura María, la estudiante cuya calificación en ortografía fue de 88. Si no existiera relación alguna entre la escritura y la ortografía, podríamos predecir una calificación de 50, que es la media general de todas las calificaciones de escritura. Si no existe relación en-




figura 6.9 Relación entre la ortografía y la escritura.

tre X y Y , la media general será la mejor predicción. Cuando no hay relación entre X y Y , el uso de la media minimiza los errores de predicción, puesto que la suma de los cuadrados de las desviaciones con respecto a ella es un mínimo. Usted reconocerá que ésta es la cuarta propiedad de la media, tal como fue analizada en el capítulo 4. Como quiera que la calificación real de María en escritura fue de 90, nuestra estimación de 50 tiene un error de 40 puntos. Así,

$$\text{Calificación real de María en escritura} - \text{Promedio del grupo} = Y_i - \bar{Y} = 90 - 50 = 40$$

Sin embargo, en este ejemplo la relación entre X y Y no es nula. Aunque no es perfecta, existe una relación mayor que cero entre X y Y . Por lo tanto, la media general de calificaciones en escritura no es la mejor predicción, sino, tal como lo hemos analizado en el capítulo, podemos utilizar la línea de regresión para estos datos como base de nuestra predicción. La línea de regresión para las calificaciones de escritura y ortografía se muestra en la figura 6.9. Utilizaremos esta línea para predecir una calificación en escritura de 75 para María. Ahora el error es de sólo 15 puntos. Así,

$$\left(\begin{array}{c} \text{Calificación real} \\ \text{de María} \end{array} \right) - \left(\begin{array}{c} \text{Predicción de la calificación} \\ \text{de María por medio de } X \end{array} \right) = Y_i - Y' = 90 - 75 = 15$$

En la figura 6.9 se puede observar que la distancia entre la calificación de María y la media de las calificaciones Y se puede separar en dos segmentos:

$$Y_i - \bar{Y} = (Y_i - Y') + (Y' - \bar{Y})$$

<i>Desviación de Y_i</i>	<i>=</i>	<i>Error en</i>	<i>+ La desviación</i>
		<i>predicción</i>	<i>de Y_i</i>
		<i>al usar la</i>	<i>explicada</i>
		<i>relación</i>	<i>mediante</i>
		<i>entre X</i>	<i>la relación</i>
		<i>y Y</i>	<i>entre X</i>
			<i>y Y</i>

El segmento $Y_i - Y'$ indica el error en la predicción. El segmento restante $Y' - \bar{Y}$ representa la parte de la desviación de Y_i que se explica mediante la relación entre X y Y . Observe que “se explica mediante la relación entre X y Y ” se abrevia con frecuencia como “explicada por X ”.

Suponga que hemos determinado la predicción de la calificación Y (Y') para cada dato X mediante la línea de regresión. Entonces podríamos hacer $Y_i - \bar{Y}$ para cada calificación. Si elevamos al cuadrado cada término $Y_i - \bar{Y}$ y hacemos una sumatoria de todos estos datos, obtendríamos:

$$\Sigma (Y_i - \bar{Y})^2 = \Sigma (Y_i - Y')^2 + \Sigma (Y' - \bar{Y})^2$$

<i>Variabilidad</i>	<i>=</i>	<i>Variabilidad</i>	<i>+ Variabilidad</i>
<i>total</i>		<i>de los</i>	<i>de Y</i>
<i>de Y</i>		<i>errores de</i>	<i>explicada</i>
		<i>predicción</i>	<i>por X</i>

Observe que $\Sigma (Y_i - \bar{Y})^2$ es la suma de los cuadrados de las calificaciones Y . Representa la variabilidad total de los datos Y . Así, esta ecuación establece que la variabilidad total de los datos Y se puede separar en dos partes: la variabilidad de los errores de predicción y la variabilidad de Y explicada por X .

Sabemos que cuando la relación es cada vez más fuerte, la predicción es cada vez más exacta. En la ecuación anterior, cuando la relación es más fuerte, los errores de predicción son menores, lo cual hace que la variabilidad de los errores de predicción

$\Sigma (Y_i - \bar{Y})^2$ también disminuya. Como la variabilidad total $\Sigma (Y_i - \bar{Y})^2$ no ha cambiado, la variabilidad de Y explicada por X , es decir, $\Sigma (Y' - \bar{Y})^2$, debe aumentar. Por lo tanto, la proporción de la variabilidad total de los datos Y que es explicada por X , a saber, $\Sigma (Y' - \bar{Y})^2 / \Sigma (Y_i - \bar{Y})^2$, es una medida de la fuerza de la relación. Se puede apreciar que si obtenemos la raíz cuadrada de esta razón y sustituimos en vez de Y' los valores adecuados, obtenemos la fórmula de cálculo para la r de Pearson. Ya antes habíamos definido a la r de Pearson como una medida del grado en que las parejas de datos ocupan posiciones idénticas u opuestas dentro de sus propias distribuciones. A partir de lo que hemos dicho, también se puede afirmar que la r de Pearson es igual a la raíz cuadrada de la proporción de la variabilidad de Y explicada por X . En forma de ecuación,

$$r = \sqrt{\frac{\Sigma (Y' - \bar{Y})^2}{\Sigma (Y_i - \bar{Y})^2}} = \sqrt{\frac{\text{Variabilidad de } Y \text{ explicada por } X}{\text{Variabilidad total de } Y}}$$

$$r = \sqrt{\text{Proporción de la variabilidad total de } Y \text{ explicada por } X}$$

Esta ecuación implica que si r crece, la proporción de la variabilidad de Y explicada por X aumenta también.

Relación de r^2 y la variabilidad explicada Si elevamos al cuadrado la ecuación anterior, obtenemos:

$$r^2 = \text{Proporción de la variabilidad total de } Y \text{ explicada por } X$$

Así, r^2 se conoce como el *coeficiente de determinación*. Como muestra la ecuación, r^2 es igual a la proporción de la variabilidad total de Y de la que es explicada por X . En el problema referente al promedio de calificaciones y el CI, la correlación era de 0.86. Si elevamos al cuadrado r , obtenemos:

$$r^2 = (0.86)^2 = 0.74$$

Esto significa que 74% de la variabilidad en Y puede ser explicado por el CI. Si resulta que el CI es un factor causal para determinar el promedio de las calificaciones, entonces r^2 nos señala que el CI explica 74% de la variabilidad observada en el promedio de calificaciones. ¿Y qué podemos decir del 26% restante? Deben existir otros factores relacionados con ese 26% restante que influyen sobre el promedio de las calificaciones. Lo importante aquí es que uno puede equivocarse al utilizar r pensando que X podría ser la causa principal de Y , cuando en realidad r^2 es la que nos indica cuál es la parte del cambio en Y que se puede atribuir a X . El error no es tan grave si se tiene un coeficiente de correlación tan alto como 0.86. Sin embargo, en las ciencias del comportamiento, esas correlaciones tan altas son poco comunes. Los coeficientes de correlación de $r = 0.50$ o 0.60 se consideran bastante altos; pero las correlaciones de esta magnitud sólo explican de 25 a 36% de la variabilidad en Y ($r^2 = 0.25$ a 0.36). La tabla 6.6 muestra la relación entre r y la variabilidad explicada, que se indica por medio de un porcentaje.

Otros coeficientes de correlación

Hasta ahora hemos analizado la correlación y describimos con cierto detalle el coeficiente de correlación lineal r de Pearson. Elegimos la r de Pearson por ser el coeficiente de correlación que aparece con más frecuencia en las investigaciones de las ciencias del comportamiento. Sin embargo, el lector debe observar que existen muchos coeficientes de correlación útiles, cada uno de los cuales es adecuado en diversas condiciones. Para decidir cuál coeficiente de correlación es más adecuado para el cálculo, es necesario considerar dos aspectos importantes, que son: la forma de la relación y la escala de medición en la que se expresan los datos.

tabla 6.6 Relación entre r y la variabilidad explicada

r	Variabilidad explicada
	r^2 (%)
0.10	1
0.20	4
0.30	9
0.40	16
0.50	25
0.60	36
0.70	49
0.80	64
0.90	81
1.00	100

Forma de la relación La elección del coeficiente de correlación apropiado para el cálculo depende de si la relación es lineal o curvilínea. Si los datos son curvilíneos, el uso de un coeficiente de correlación como la r de Pearson puede subestimar seriamente el grado de relación que existe entre X y Y . Según lo anterior, se utiliza otro coeficiente de correlación η (eta) para las relaciones curvilíneas. Como η no aparece a menudo en la investigación de las ciencias del comportamiento, no presentaremos un análisis de la misma.¹ Sin embargo, esto pone de manifiesto la importancia de utilizar una gráfica de dispersión para determinar si la relación es lineal, antes de seguir adelante de manera rutinaria con el cálculo de un coeficiente de correlación lineal.

Escala de medición La elección del coeficiente de correlación depende también del tipo de escala de medición en que han sido expresados los datos. Ya hemos analizado el coeficiente de correlación lineal r de Pearson. En él se supone que los datos se miden en una escala de intervalo o de razón. Otros ejemplos de coeficientes de correlación lineal son: el coeficiente de correlación de rangos ordenados de Spearman rho (r_s), el coeficiente de correlación biserial (r_b), y el coeficiente phi (ϕ). En realidad, cada uno de estos coeficientes es la ecuación para la r de Pearson, simplificada para aplicarla a una escala de menor orden. Rho se utiliza cuando una o ambas variables tienen una escala ordinal, r_b se utiliza cuando una de las variables se mide al menos en intervalos y la otra es dicotómica, y phi se utiliza cuando cada una de las variables es dicotómica. Aunque la presentación detallada de cada coeficiente de correlación va más allá del alcance de este texto, el coeficiente de correlación de rangos ordenados de Spearman, rho, aparece con la frecuencia suficiente para que una exposición del mismo resulte justificada.

El coeficiente de correlación de rangos ordenados de Spearman rho (r_s) Tal como lo hemos mencionado, el coeficiente de correlación de rangos ordenados de Spearman, rho, se utiliza cuando una o ambas variables corresponden sólo a una escala ordinal. La rho de Spearman es en realidad el coeficiente de correlación lineal r de Pearson aplicado a datos que satisfacen los requisitos de una escala ordinal. La ecuación más sen-

¹Una exposición sobre η y los demás coeficientes que aparecen en esta sección se encuentra en N. Downie y R. Heath, *Basic Statistical Methods*, cuarta edición, Harper & Row, Nueva York, 1974, pp. 102-114.

cilla para el cálculo de rho cuando no existen empates, o cuando existen muy pocos de ellos, con respecto al número de parejas de datos es:

$$r_s = 1 - \frac{6 \sum D_i^2}{N^3 - N} \quad \text{ecuación para el cálculo de rho}$$

donde D_i = diferencia entre el i -ésimo par de rangos = $R(X_i) - R(Y_i)$

$R(X_i)$ = rango del i -ésimo dato X

$R(Y_i)$ = rango del i -ésimo dato Y

N = número de parejas de rangos

Se puede demostrar que si entre los datos ordinales no existen empates, la r de Pearson se reduce algebraicamente a la ecuación anterior.

Para ilustrar el uso de rho, consideremos un ejemplo. Suponga que una gran corporación está interesada en calificar a un grupo de 12 aspirantes a gerentes, según su capacidad de liderazgo. Se ha contratado a dos psicólogos para realizar ese trabajo. Como resultado de sus exámenes y entrevistas, cada uno de los psicólogos, de manera independiente, ha ordenado por rangos a los aspirantes según su capacidad de liderazgo. Los rangos van de 1 a 12, donde 1 representa el nivel máximo de capacidad de liderazgo. Los datos se presentan en la tabla 6.7. ¿Cuál es la correlación entre los ordenamientos por rangos obtenidos por los dos psicólogos?

En virtud de que los datos tienen una escala ordinal, tenemos que calcular rho. La solución aparece en la tabla 6.7. Observe que los sujetos 5 y 6 quedaron empatados en el ordenamiento por rangos del psicólogo A. Cuando ocurren empates, la regla sugiere asignar a cada sujeto el promedio de los rangos empatados. Por ejemplo, los sujetos 5 y 6 quedaron empatados en los rangos 2 y 3. Por lo tanto, cada uno tuvo una clasificación de 2.5 $[(2 + 3)/2 = 2.5]$. Al asignar a los dos sujetos una clasificación de 2.5, utilizamos los rangos 2 y 3. El siguiente rango es 4. D_i es la diferencia entre las parejas de rangos para


tabla 6.7 Cálculo de r_s para el ejemplo del liderazgo

Sujeto	Orden de rango del psicólogo A $R(X_i)$	Orden de rango del psicólogo B $R(Y_i)$	$D_i =$ $R(X_i) - R(Y_i)$	D_i^2
1	6	5	1	1
2	5	3	2	4
3	7	4	3	9
4	10	8	2	4
5	2.5	1	1.5	2.25
6	2.5	6	-3.5	12.25
7	9	10	-1	1
8	1	2	1	1
9	11	9	2	4
10	4	7	3	9
11	8	11	-3	9
12	12	12	0	0
$N=12$				$\sum D_i^2 = 56.5$

$$r_s = 1 - \frac{6 \sum D_i^2}{N^3 - N} = 1 - \frac{6(56.5)}{(12)^3 - 12} = 1 - \frac{339}{1716} = 0.80$$

el i -ésimo sujeto. De esta manera, $D_i = 1$ para el sujeto 1. No importa si se resta R de $R(Y_i)$ o $R(X_i)$ de $R(X_i)$ para obtener D_i puesto que elevamos al cuadrado cada valor D_i . Luego se suman los cuadrados de las D_i ($\sum D_i^2 = 56.5$). Este valor se introduce después en la ecuación, junto con N ($N = 12$), para calcular r_s . Para este problema,

$$r_s = 1 - \frac{6 \sum D_i^2}{N^3 - N} = 1 - \frac{6(56.5)}{12^3 - 12} = 1 - \frac{339}{1716} = 0.80$$



Para ilustrar el cálculo de r_s , suponga que las calificaciones de las actitudes y el grado de atracción mutua planteadas en el problema de práctica 6.2 fuesen sólo de una escala ordinal. Bajo esta hipótesis, determine el valor del coeficiente de correlación lineal rho para estos datos y compárelo con la r de Pearson obtenida en el problema de práctica 6.2.

SOLUCIÓN

Los datos y la solución se presentan en la tabla siguiente.

Sujeto	Proporción de actitudes similares X_i	Atracción Y_i	Rango de X_i $R(X_i)$	Rango de Y_i $R(Y_i)$	$D_i =$ $R(X_i) - R(Y_i)$	D_i^2
1	0.30	8.9	5	7	2	4
2	0.44	9.3	7	8	-1	1
3	0.67	9.6	11	10	1	1
4	0.00	6.2	1	1	0	0
5	0.50	8.8	8	6	2	4
6	0.15	8.1	3	5	-2	4
7	0.58	9.5	9	9	0	0
8	0.32	7.1	6	2	4	16
9	0.72	11.0	12	13	-1	1
10	1.00	11.7	15	15	0	0
11	0.87	11.5	14	14	0	0
12	0.09	7.3	2	3	-1	1
13	0.82	10.0	13	11.5	1.5	2.25
14	0.64	10.0	10	11.5	1.5	2.25
15	0.24	7.5	4	4	0	0
$N = 15$						$\sum D_i^2 = 36.5$

$$r_s = 1 - \frac{6 \sum D_i^2}{N^3 - N} = 1 - \frac{6(36.5)}{(15)^3 - 15} = 1 - \frac{219}{3360} = 0.93$$

Observe que $r_s = 0.93$ y que $r = 0.94$. Los valores no son idénticos, pero sí muy cercanos entre sí. En general, al calcular la r de Pearson utilizando las propiedades de intervalo o de razón de los datos, sus valores serán cercanos, aunque no exactamente iguales, a los que se obtendrían considerando únicamente las propiedades ordinales de aquellos datos.

Efecto del rango sobre la correlación

Si existe una correlación entre X y Y , la restricción del rango de cualquiera de las variables tendrá el efecto de *reducir* dicha correlación. Podemos ver esto en la figura 6.10, donde hemos trazado una gráfica de dispersión del promedio de las calificaciones de los estudiantes de primer año, y las calificaciones según el Comité para el Examen de Ingreso a la Universidad (CEEI, por sus siglas en inglés). Subdividimos la figura en calificaciones CEEI bajas, medias y altas. Al estimar la figura como un todo, es decir, al considerar todo el rango de las calificaciones del CEEI, hay una alta correlación entre las dos variables. Sin embargo, si consideramos las tres secciones por separado, la correlación de cada sección será mucho menor. Dentro de cada sección, los puntos muestran un cambio menos sistemático en Y con respecto a los cambios en X . Esto, por supuesto, indica una correlación menor entre X y Y . El efecto de la restricción del rango sobre la correlación se presenta con frecuencia en la educación o en la industria. Por ejemplo, suponga que sobre la base de la correlación alta entre las calificaciones de los estudiantes de primer año y las calificaciones del CEEI de la figura 6.10, una universidad decide admitir solamente a los graduados del bachillerato que hayan obtenido calificaciones dentro del rango alto de las calificaciones del CEEI. Si las calificaciones obtenidas posteriormente por estos estudiantes fueran correlacionadas con sus calificaciones del CEEI, esperaríamos ver una correlación mucho más baja, debido a la restricción de rango de las calificaciones del CEEI para estos estudiantes de primer grado. De manera similar, si alguien realiza un estudio de correlación y obtiene un coeficiente de correlación bajo, habrá que verificar si la restricción del rango no es la causa de este valor bajo.




figura 6.10 Calificaciones de los estudiantes de primer grado y calificaciones CEEI.

Efecto de los datos extremos

Consideremos el efecto de un dato extremo sobre la magnitud del coeficiente de correlación. La figura 6.11(a) muestra un conjunto de datos en el que todos éstos se agrupan con un grado razonable de proximidad. El valor de la r de Pearson para este conjunto de datos es de 0.11. La figura 6.11(b) muestra el mismo conjunto de datos, pero se le ha agregado un dato extremo. El valor de la r de Pearson para este conjunto de datos es de 0.94. La magnitud de la r de Pearson ha cambiado de 0.11 a 0.94. Esto es una demostración del argumento según el cual *un dato extremo puede alterar drásticamente la magnitud del coeficiente de correlación* y, por lo tanto, modifica la interpretación de los datos. En consecuencia, antes de calcular el coeficiente de correlación, es conveniente examinar la gráfica de dispersión de los datos para comprobar si contiene datos extremos. Si tales datos extremos están presentes, se deberá tener cuidado al interpretar la relación. Si se trata de una muestra aleatoria grande, un valor extremo no alterará considerablemente, de ordinario, la magnitud de la correlación. En cambio, si la muestra es pequeña, como la de este ejemplo, un valor extremo puede producir un efecto grande.

La correlación no implica causalidad

Cuando existe una correlación entre dos variables (X y Y) es tentador concluir que una de ellas es la causa de la otra. Sin embargo, aceptar esto sin mayor investigación sería un grave error, pues siempre que dos variables estén correlacionadas puede haber cuatro explicaciones posibles de esa correlación: 1) la correlación entre X y Y degeneró en su origen, es espuria; 2) X es la causa de Y ; 3) Y es la causa de X , y 4) una tercera variable es la causa de la correlación entre X y Y . La primera posibilidad corresponde al caso en que la correlación exhibida por la muestra se debe a accidentes al realizar el muestreo de personas o comportamientos inusuales; es decir, que si el experimento se repitiera o si se tomaran más muestras, tal correlación desaparecería. Si la correlación es espuria en realidad, es obvio que sería incorrecto concluir que existe una relación causal entre X y Y .




figura 6.11 Efecto de un dato extremo sobre la magnitud del coeficiente de correlación.

También es erróneo suponer una causalidad entre X y Y si la cuarta alternativa es correcta. Con mucha frecuencia, cuando X y Y están correlacionadas, no tienen una relación causal entre sí, sino que una tercera variable es responsable de esa correlación. Por ejemplo, ¿sabe usted que existe una relación estrecha entre los salarios de los profesores universitarios y el precio de una botella de whisky escocés? ¿Cuál es la causa y cuál el efecto de esto? ¿Acaso los salarios de los maestros universitarios dominan el mercado del whisky escocés, a tal grado que cuando los profesores reciben un aumento de sueldo y por ende pueden comprar más whisky, el precio de éste se incrementa en forma correspondiente? ¿O acaso a los profesores universitarios se les paga con las ganancias de las ventas de whisky escocés, de tal manera que cuando ellos necesitan un aumento, el precio de esta bebida se incrementa? En realidad, ninguna de estas explicaciones es correcta, pues la verdad es que existe un tercer factor responsable de esa correlación. ¿Cuál es ese factor? ¡La inflación! Hace poco, un artículo periodístico informó que había una correlación positiva entre la obesidad y la criminalidad femenina. ¿Significa esto que si una mujer aumenta 10 kilogramos se convertirá en criminal? O bien, ¿significa que si una mujer es criminal, está condenada a ser obesa? Ninguna de estas explicaciones parece ser satisfactoria. Francamente, no estamos seguros de cómo interpretar semejante correlación. Es posible que la correlación haya degenerado en su origen, es decir, sea espuria. También podría deberse a un tercer factor, como el nivel socioeconómico. Tanto la obesidad como la delincuencia están relacionadas con un nivel socioeconómico bajo.

El argumento es que la presencia de una correlación entre dos variables no basta para afirmar que existe una relación de causalidad entre ellas. Hay otras explicaciones posibles. Para establecer que una variable es la causa de otra, es necesario llevar a cabo un experimento en el cual se modifique de manera sistemática *sólo* la variable supuestamente causal y se mida el efecto que produce sobre la otra variable.