


Regresión lineal



Introducción

Predicción y relaciones imperfectas

Construcción de la recta de regresión por mínimos cuadrados: Regresión de Y sobre X

Regresión de X sobre Y

Medición de errores de predicción: el error estándar de la estimación

Consideraciones al utilizar la regresión lineal para la predicción

Relación entre las constantes de regresión y la r de Pearson

Regresión múltiple y correlación múltiple

Resumen

Términos importantes

Preguntas y problemas



INTRODUCCIÓN

La regresión y la correlación están íntimamente relacionadas entre sí. En el nivel más elemental, ambas implican la relación entre dos variables y utilizan el mismo conjunto de datos básicos: las parejas de datos obtenidas de los mismos sujetos o de otros que forman parejas con ellos. Como estudiamos en el capítulo 6, la correlación tiene que ver con la magnitud y la dirección de la relación. La regresión se centra en el uso de la relación para elaborar una predicción. La predicción resulta bastante fácil de establecer cuando la relación es perfecta. Cuando esto sucede, todos los puntos están localizados sobre una línea recta y lo único que tenemos que hacer es obtener la ecuación de esa recta y utilizarla para llevar a cabo la predicción. Como puede suponer, cuando la relación es perfecta, también lo es la predicción. Todos los valores predichos son exactamente iguales a los valores observados y el error de predicción es igual a cero. La situación es más compleja cuando la relación es imperfecta.

definición ■ La **regresión** es un tema en el que se aplica la relación entre dos o más variables con propósitos de predicción.



PREDICCIÓN Y RELACIONES IMPERFECTAS

Consideremos de nuevo los datos referentes al promedio de las calificaciones y el CI, presentados en el capítulo 6. Por comodidad, hemos reproducido esos datos en la tabla 7.1. La figura 7.1 muestra una gráfica de dispersión o dispersigrama correspondiente a dichos datos. La relación es imperfecta, positiva y lineal. El problema de predicción que nos ocupa consiste en hallar una sola línea recta que describa esos datos mejor que cualquier otra. La solución que se usa más frecuentemente consiste en construir la recta que minimice los errores de predicción de acuerdo con el criterio de los *mínimos cuadrados*. Esa línea tiene el nombre, muy apropiado, de *recta de regresión por mínimos cuadrados*.

La recta de regresión por mínimos cuadrados para los datos de la tabla 7.1 aparece en la figura 7.2(a). La distancia vertical entre cada punto y la recta representa el error de la predicción. Si Y' es la predicción del valor Y y Y es el valor real, entonces $Y - Y'$ es el error para cada punto. Parecería que el error total de la predicción sería la suma algebraica simple de $Y - Y'$, sumado sobre todos los puntos. Si esto fuese cierto, y como estamos interesados en minimizar el error, construiríamos la recta que minimiza $\sum (Y - Y')$. Sin embargo, el error total de la predicción no es igual a $\sum (Y - Y')$ porque algunos de los valores Y' serán mayores que Y y otros serán menores. Así, habrá errores positivos y negativos, y las sumas algebraicas simples de estos errores se cancelarán entre sí. Ya nos encontramos con una situación similar cuando medimos el promedio de las dispersiones. Al deducir la ecuación de la desviación estándar, elevamos al cuadrado $X - \bar{X}$ para compensar el hecho de que había desviaciones positivas y negativas que se cancelaban entre sí. Aquí funciona también esta solución. En vez de sólo sumar $Y - Y'$, primero calcularemos $(Y - Y')^2$ para cada calificación. Esto elimina los valores negativos y el problema de cancelación queda resuelto. Ahora, si minimizamos $\sum (Y - Y')^2$, minimizamos el error total de la predicción.

tabla 7.1 CI y promedio de calificaciones de 12 estudiantes

Estudiante núm.	CI	Promedio de calificaciones
1	110	1.0
2	112	1.6
3	118	1.2
4	119	2.1
5	122	2.6
6	125	1.8
7	127	2.6
8	130	2.0
9	132	3.2
10	134	2.6
11	136	3.0
12	138	3.6




figura 7.1 Gráfica de dispersión del CI y el promedio de calificaciones.





figura 7.2 Dos rectas de regresión y el error de predicción.

definición ■ *La línea de regresión por mínimos cuadrados es la línea de predicción que minimiza $\sum (Y - Y')^2$.*

Para cualquier relación lineal existe una única recta que minimiza $\sum (Y - Y')^2$. Por consiguiente, no existe más que una recta de regresión por mínimos cuadrados para cada relación lineal.

Habíamos dicho que es factible construir muchas líneas de predicción “posibles” cuando la relación es imperfecta. ¿Por qué deberíamos utilizar la línea de regresión por mínimos cuadrados? La empleamos porque es útil, ya que nos facilita la predicción con máxima precisión global. Para ilustrar este punto, en la figura 7.2(b) trazamos otra línea de predicción. Elegimos esta recta de manera arbitraria y es sólo una de la infinidad de líneas que podríamos haber trazado. ¿Cómo se compara la precisión de esta predicción con la de la recta de regresión por mínimos cuadrados? Podemos apreciar que en realidad se ajusta mejor a algunos puntos (por ejemplo, en los puntos A y B). Sin embargo, falla terriblemente en otros (por ejemplo, en los puntos C y D). Si consideramos todos los puntos, resulta claro que la recta de la figura 7.2(a) se ajusta mejor a los puntos que la recta de la figura 7.2(b). El error total de la predicción, representado por $\sum (Y - Y')^2$, es menor para la línea de regresión por mínimos cuadrados que para la recta de la figura 7.2(b). De hecho, el error total de predicción es menor con la línea de regresión por mínimos cuadrados que con cualquier otra recta de predicción posible. Así, utilizamos la recta de regresión por mínimos cuadrados porque proporciona predicciones con mayor precisión general que cualquier otra línea de regresión posible.



CONSTRUCCIÓN DE LA RECTA DE REGRESIÓN POR MÍNIMOS CUADRADOS: REGRESIÓN DE Y SOBRE X

La ecuación de la recta de regresión por mínimos cuadrados para predecir Y conociendo X es:

$$Y' = b_Y X + a_Y \quad \text{ecuación de regresión lineal para predecir } Y \text{ conociendo } X$$

donde Y' = el valor predicho o estimado de Y

b_Y = la pendiente de la recta que minimiza los errores en la predicción de Y

a_Y = Y la ordenada al origen de la recta que minimiza los errores en la predicción de Y

Esta es, por supuesto, la ecuación general de la recta que hemos utilizado todo el tiempo. Sin embargo, en este contexto, a_Y y b_Y se llaman *constantes de regresión*. Esta línea se llama recta de regresión de Y sobre X , o simplemente la regresión de Y sobre X , en virtud de que intentamos predecir Y a partir de una X conocida.

La constante de regresión b_Y es igual a:

$$b_Y = \frac{\sum XY - \frac{(\sum X)(\sum Y)}{N}}{SC_X}$$

donde SC_X = la suma de los cuadrados de los datos $X = \sum X^2 - \frac{(\sum X)^2}{N}$
 N = el número de *parejas* de datos

ΣXY = suma del producto de cada pareja X y Y (también conocida como la suma de los productos cruzados)

La ecuación para calcular b_Y a partir de los datos en bruto es:

$$b_Y = \frac{\Sigma XY - \frac{(\Sigma X)(\Sigma Y)}{N}}{\Sigma X^2 - \frac{(\Sigma X)^2}{N}} \quad \text{ecuación que permite calcular la constante de regresión } b \text{ para predecir } Y \text{ conociendo } X$$

La constante de regresión a_Y está dada por:

$$a_Y = \bar{Y} - b_Y \bar{X} \quad \text{ecuación para calcular la constante de regresión } a \text{ para predecir } Y \text{ conociendo } X$$

Como necesitamos la constante b_Y para determinar la constante a_Y el procedimiento consiste en hallar primero b_Y y después a_Y . Una vez determinadas ambas, éstas se sustituyen en la ecuación de regresión. Construyamos la línea de regresión por mínimos cuadrados para los datos del CI y las calificaciones que presentamos anteriormente. Por comodidad, los datos han sido presentados de nuevo en la tabla 7.2.

tabla 7.2 CI y promedio de las calificaciones de 12 estudiantes universitarios: predicción de Y a partir de X

Estudiante núm.	CI X	Promedio de las calificaciones		XY	X^2
		Y			
1	110	1.0		110.0	12 100
2	112	1.6		179.2	12 544
3	118	1.2		141.6	13 924
4	119	2.1		249.9	14 161
5	122	2.6		317.2	14 884
6	125	1.8		225.0	15 625
7	127	2.6		330.2	16 129
8	130	2.0		260.0	16 900
9	132	3.2		422.4	17 424
10	134	2.6		348.4	17 956
11	136	3.0		408.0	18 496
12	138	3.6		496.8	19 044
Total	1503	27.3		3488.7	189 187

$$b_Y = \frac{\Sigma XY - \frac{(\Sigma X)(\Sigma Y)}{N}}{\Sigma X^2 - \frac{(\Sigma X)^2}{N}} = \frac{3488.7 - \frac{1503(27.3)}{12}}{189\,187 - \frac{(1503)^2}{12}}$$

$$= \frac{69.375}{936.25} = 0.0741 = 0.074$$

$$a_Y = \bar{Y} - b_Y \bar{X} = 2.275 - 0.0741(125.25) = -7.006$$

$$Y' = b_Y X + a_Y = 0.074X - 7.006$$

$$\begin{aligned}
 b_Y &= \frac{\sum XY - \frac{(\sum X)(\sum Y)}{N}}{\sum X^2 - \frac{(\sum X)^2}{N}} \\
 &= \frac{3488.7 - \frac{1503(27.3)}{12}}{189.187 - \frac{(1503)^2}{12}} \\
 &= \frac{69.375}{936.25} = 0.0741 = 0.074 \\
 a_Y &= \bar{Y} - b_Y \bar{X} \\
 &= 2.275 - 0.0741(125.25) \\
 &= -7.006
 \end{aligned}$$

y también

$$Y' = 0.074X - 7.006$$

La solución completa aparece también en la tabla 7.2. La gráfica de la línea de regresión se presenta en la figura 7.3. Ahora podemos usar la ecuación para Y' para predecir el promedio de calificaciones, conociendo solamente el CI del estudiante. Por ejemplo, supongamos que el CI del estudiante es de 124; al emplear esta línea de regresión, ¿cuál es la predicción del promedio de las calificaciones del estudiante?

$$\begin{aligned}
 Y' &= 0.074X - 7.006 \\
 &= 0.074(124) - 7.006 \\
 &= 2.17
 \end{aligned}$$




figura 7.3 Recta de regresión para el promedio de calificaciones y el CI.

Resolvamos un par de problemas de práctica.

Problema de práctica 7.1

Una psicóloga del desarrollo está interesada en determinar si es posible utilizar la estatura de los niños como base para predecir su posible estatura en la edad adulta. Para resolver esta cuestión, ha reunido los datos que aparecen en la tabla siguiente.

- Trace una gráfica de dispersión para los datos.
- Si los datos están relacionados de manera lineal, deduzca la recta de regresión por mínimos cuadrados.
- Con base en estos datos, ¿qué estatura podría predecir para una persona de 20 años si a los tres años de edad tenía una altura de 42 pulgadas?

Individuo número	Estatura a la edad de 3 años X (pulgadas)	Estatura a la edad de 20 años Y (pulgadas)	XY	X^2
1	30	59	1770	900
2	30	63	1890	900
3	32	62	1984	1024
4	33	67	2211	1089
5	34	65	2210	1156
6	35	61	2135	1225
7	36	69	2484	1296
8	38	66	2508	1444
9	40	68	2720	1600
10	41	65	2665	1681
11	41	73	2993	1681
12	43	68	2924	1849
13	45	71	3195	2025
14	45	74	3330	2025
15	47	71	3337	2209
16	48	75	3600	2304
<i>Total</i>	618	1077	41 956	24 408

$$b_Y = \frac{\sum XY - \frac{(\sum X)(\sum Y)}{N}}{\sum X^2 - \frac{(\sum X)^2}{N}} = \frac{41\,956 - \frac{618(1077)}{16}}{24\,408 - \frac{(618)^2}{16}} = 0.6636 = 0.664$$

$$a_Y = \bar{Y} - b_Y \bar{X} = 67.3125 - 0.6636(38.625) = 41.681$$

$$Y' = b_Y X + a_Y = 0.664X + 41.681$$

SOLUCIÓN

- a. La gráfica de dispersión se presenta en la figura siguiente. Está claro que existe una relación imperfecta, lineal y positiva entre las estaturas a las edades de 3 y 20 años.
- b. Obtención de la recta de regresión por mínimos cuadrados.

$$Y' = b_Y X + a_Y$$


$$b_Y = \frac{\sum XY - \frac{(\sum X)(\sum Y)}{N}}{\sum X^2 - \frac{(\sum X)^2}{N}} = \frac{41\,956 - \frac{618(1077)}{16}}{24\,408 - \frac{(618)^2}{16}}$$
$$= 0.6636 = 0.664$$

$$a_Y = \bar{Y} - b_Y \bar{X} = 67.3125 - 0.6636(38.625)$$
$$= 41.681$$

Por lo tanto,

$$Y' = b_Y X + a_Y = 0.664X + 41.681$$

Esta solución se presenta también en la tabla anterior. La recta de regresión por mínimos cuadrados se muestra sobre la gráfica de dispersión siguiente.



- c. Predicción de la estatura para el niño de 3 años de edad que mide 42 pulgadas:

$$Y' = 0.664X + 41.681$$
$$= 0.664(42) + 41.681$$
$$= 69.57 \text{ pulgadas}$$

Problema de práctica 7.2

Una neuróloga sospecha que los bajos niveles de serotonina, un neurotransmisor cerebral, pueden estar relacionados de manera causal con el comportamiento agresivo. Como primer paso en su investigación, esta científica decide realizar un estudio de correlación con nueve macacos de la India. Los monos son observados durante 6 meses y se registra el número de actos agresivos que realizan. También se miden los niveles de serotonina en el estriátum (una región del cerebro asociada con el comportamiento agresivo) una vez al día en cada animal. Los datos resultantes se presentan en la tabla siguiente. El número de actos agresivos por cada animal es el promedio de los 6 meses, expresado sobre una base diaria. Los niveles de serotonina también son los valores promedio durante el periodo de 6 meses.

- Trace una gráfica de dispersión para los datos.
- Si los datos están relacionados de manera lineal, obtenga la recta de regresión por mínimos cuadrados para predecir el número de actos agresivos a partir del nivel de serotonina.
- Con base en estos datos, ¿cuál es el número de actos agresivos por día que se podría predecir si en cierto macaco se midió un nivel de serotonina de 0.46 microgramos/gramo?

Sujeto número	Nivel de serotonina (microgramos/gramo) X	Número de actos agresivos/día Y	XY	X^2
1	0.32	6.0	1.920	0.1024
2	0.35	3.8	1.330	0.1225
3	0.38	3.0	1.140	0.1444
4	0.41	5.1	2.091	0.1681
5	0.43	3.0	1.290	0.1849
6	0.51	3.8	1.938	0.2601
7	0.53	2.4	1.272	0.2809
8	0.60	3.5	2.100	0.3600
9	0.63	2.2	1.386	0.3969
Total	4.16	32.8	14.467	2.0202


$$b_Y = \frac{\sum XY - \frac{(\sum X)(\sum Y)}{N}}{\sum X^2 - \frac{(\sum X)^2}{N}} = \frac{14.467 - \frac{(4.16)(32.8)}{9}}{2.0202 - \frac{(4.16)^2}{9}} = -7.127$$

$$a_Y = \bar{Y} - b_Y \bar{X} = 3.6444 - (-7.1274)(0.4622) = 6.939$$

$$Y' = b_Y X + a_Y = -7.127X + 6.939$$

SOLUCIÓN

- a. A continuación se muestra la gráfica de dispersión. Está claro que existe una relación imperfecta, lineal y negativa entre las dos variables.



- b. Encuentre la recta de regresión por mínimos cuadrados. La solución se presenta al pie de la tabla precedente y la recta de regresión ha sido trazada sobre la gráfica de dispersión que aparece arriba.
- c. Predicción del número de actos agresivos:

$$\begin{aligned}
 Y' &= -7.127X + 6.939 \\
 &= -7.127(0.46) + 6.939 \\
 &= 3.7 \text{ actos agresivos por día}
 \end{aligned}$$

**REGRESIÓN DE X SOBRE Y**

Hasta ahora nos hemos ocupado de predecir los datos Y a partir de los datos X . Para lograrlo, obtuvimos una línea de regresión que nos permitió predecir Y conociendo X . Esta línea se conoce a veces como la *recta de regresión de Y sobre X* . También es posible predecir X conociendo Y . Sin embargo, para predecir X conociendo Y , debemos obtener una nueva recta de regresión. No podemos utilizar la ecuación de regresión para la predicción de Y cuando se conoce X . Por ejemplo, en el problema referente al CI (X) y el promedio de las calificaciones (Y), obtuvimos la siguiente recta de regresión:

$$Y' = 0.074X - 7.006$$

Esta recta resultó apropiada para predecir el promedio de calificaciones cuando el CI es conocido; es decir, para predecir Y conociendo X . Sin embargo, si queremos predecir el CI (X) cuando el promedio de calificaciones (Y) es conocido, no podemos utilizar esta recta de regresión. Ahora tendremos que obtener nuevas constantes de regresión, puesto que la recta de regresión anterior fue calculada con el propósito de minimizar los errores en la variable Y . Los errores que minimizamos han sido representados mediante rectas verticales paralelas al eje Y [véase la figura 7.2(a)]. Ahora queremos minimizar los errores en la variable X . Estos errores se representarían por medio de rectas horizontales paralelas al eje X . Un ejemplo ilustrativo de esto se representa en la figura 7.2(a), por medio de la línea punteada que une el punto E con la recta de regresión.

En términos generales, el proceso de minimizar los errores en Y' y el de minimizar los errores en X' no conducen a las mismas líneas de regresión. La excepción se presenta cuando la relación es perfecta. En este caso, ambas líneas de regresión coinciden, formando una recta única que pasa por todos los puntos. La línea de regresión para la predicción de X a partir de Y se conoce a veces como la *recta de regresión de X sobre Y* , o simplemente como la *regresión de X sobre Y* . Para ilustrar el cálculo de la línea emplearemos de nuevo los datos del CI y el promedio de calificaciones. Sin embargo, esta vez haremos la predicción del CI (X) a partir del promedio de las calificaciones (Y). Por comodidad, los datos se presentan ahora en la tabla 7.3. La ecuación de regresión lineal para predecir X dado Y es.

$$X' = b_X Y + a_X \quad \text{ecuación de regresión lineal para predecir } X \text{ dado } Y$$

tabla 7.3 CI y promedio de calificaciones de 12 estudiantes: Predicción de X a partir de Y

Estudiante número	CI X	Promedio de calificaciones Y	XY	Y^2
1	110	1.0	110.0	1.00
2	112	1.6	179.2	2.56
3	118	1.2	141.6	1.44
4	119	2.1	249.9	4.41
5	122	2.6	317.2	6.76
6	125	1.8	225.0	3.24
7	127	2.6	330.2	6.76
8	130	2.0	260.0	4.00
9	132	3.2	422.4	10.24
10	134	2.6	348.4	6.76
11	136	3.0	408.0	9.00
12	138	3.6	496.8	12.96
Total	1503	27.3	3488.7	69.13

$$b_X = \frac{\sum XY - \frac{(\sum X)(\sum Y)}{N}}{\sum Y^2 - \frac{(\sum Y)^2}{N}} = \frac{3488.7 - \frac{1503(27.3)}{12}}{69.13 - \frac{(27.3)^2}{12}}$$

$$= \frac{69.375}{7.0225} = 9.879$$

$$a_X = \bar{X} - b_X \bar{Y} = 125.25 - 9.879(2.275) = 102.775$$

$$X' = b_X Y + a_X = 9.879Y + 102.775$$

donde X' = predicción del valor de X

b_X = pendiente de la recta que minimiza los errores en X'

a_X = intersección con el eje X de la recta que minimiza los errores en X'

Las ecuaciones para b_X y a_X son

$$b_X = \frac{\sum XY - \frac{(\sum X)(\sum Y)}{N}}{SC_Y} = \frac{(\sum XY) - \frac{(\sum X)(\sum Y)}{N}}{\sum Y^2 - \frac{(\sum Y)^2}{N}}$$

ecuación para el cálculo de la constante de regresión b para predecir X conociendo Y

donde SC_Y = suma de los cuadrados de los datos Y

$$= \sum Y^2 - \frac{(\sum Y)^2}{N}$$

$a_X = \bar{X} - b_X \bar{Y}$ constante de regresión a para predecir X conociendo Y

despejando b_X y a_X ,

$$b_X = \frac{\sum XY - \frac{(\sum X)(\sum Y)}{N}}{\sum Y^2 - \frac{(\sum Y)^2}{N}}$$

$$b_X = \frac{3488.7 - \frac{1503(27.3)}{12}}{69.13 - \frac{(27.3)^2}{12}} = \frac{69.375}{7.0225} = 9.879$$




figura 7.4 Regresión de X sobre Y y regresión de Y sobre X.

$$\begin{aligned}
 a_X &= \bar{X} - b_X \bar{Y} \\
 &= 125.25 - 9.8790(2.275) \\
 &= 102.775
 \end{aligned}$$

La ecuación de regresión lineal para predecir X a partir de Y es

$$\begin{aligned}
 X' &= b_X Y + a_X \\
 &= 9.879Y + 102.775
 \end{aligned}$$

La figura 7.4 muestra esta recta, junto con la línea para la predicción de Y dado X . Observe que las dos rectas son distintas, tal como sería de esperar en virtud de que la relación es imperfecta. La solución se presenta resumida en la tabla 7.3.

Aunque existen diferentes ecuaciones para calcular la segunda recta de regresión, éstas se utilizan en muy pocas ocasiones. En lugar de eso, a la variable por predecir se la designa en la práctica como Y' y a la variable conocida se la designa como X . Así pues, si quisiéramos predecir el CI a partir del promedio de las calificaciones, designaríamos al CI como la variable Y' y al promedio de calificaciones como la variable X , para luego utilizar la ecuación de regresión para predecir Y conociendo X .



MEDICIÓN DE ERRORES DE PREDICCIÓN: EL ERROR ESTÁNDAR DE LA ESTIMACIÓN

La recta de regresión representa nuestra mejor estimación de los datos Y a partir de los valores X correspondientes. Sin embargo, a menos que la relación entre X y Y sea perfecta, la mayor parte de los valores reales de Y no estarán sobre la línea de regresión. Así pues, cuando la relación es imperfecta, necesariamente habrá errores en la predicción y será útil conocer la magnitud de éstos. Por ejemplo, tomando como base la relación entre el CI y el promedio de las calificaciones que vimos con anterioridad, parecería correcto afirmar que el promedio de calificaciones de John será de 3.2 cuando curse su último año de estudios de licenciatura. Sin embargo, considerando que la relación es imperfecta, es poco probable que nuestra predicción sea exacta. Bien, pero si no es perfecta, entonces ¿qué tan grande es el error? Si resulta probable que el error sea muy grande, entonces no podremos confiar mucho en la predicción. Sin embargo, si el error es pequeño, podremos tomar en serio la predicción y la utilizaremos como base para nuestras decisiones.

La medición de los errores de predicción requiere el cálculo del error estándar de la estimación. Este error es similar a la desviación estándar. Como usted recordará, la desviación estándar nos proporciona una medida de la desviación promedio en torno de la media. El error estándar de la estimación nos proporciona una medida de la desviación promedio de los errores de predicción en torno de la recta de regresión. En este contexto, la recta de regresión se puede considerar como una estimación de la media de los valores de Y para cada uno de los valores de X . Es algo así como una media “flotante” de los valores de Y , que cambia con valores de X . Con la desviación estándar, la suma de las desviaciones, $\Sigma (X - \bar{X})$, era igual a 0. Tuvimos que elevar al cuadrado las desviaciones para obtener un promedio significativo. La situación es la misma con el error estándar de la estimación. Como quiera que la suma de los errores de predicción, $\Sigma (Y - Y')$, es igual a 0, también debemos elevarlos al cuadrado. A continuación, obtenemos el promedio sumando los valores elevados al cuadrado, dividiendo entre $N - 2$, y extrayendo la raíz cuadrada del cociente (de una manera muy similar al caso de la desviación estándar). La ecuación para calcular el error estándar de la estimación para predecir Y conociendo X es

$$s_{Y|X} = \sqrt{\frac{\Sigma (Y - Y')^2}{N - 2}} \quad \text{error estándar de la estimación al predecir } Y \text{ dado } X$$


Observe que hemos dividido entre $N - 2$ y no entre $N - 1$, como en el caso de la desviación estándar de una muestra.* Los cálculos que intervienen en el uso de esta ecuación son bastante laboriosos. La ecuación que presentamos aquí para realizar dicho cálculo es mucho más sencilla de aplicar. Al determinar el coeficiente de regresión b_Y , ya habíamos calculado los valores de SC_X y SC_Y .

$$s_{Y|X} = \sqrt{\frac{SC_Y - \frac{[\sum XY - (\sum X)(\sum Y)/N]^2}{SC_X}}{N - 2}}$$

Para ilustrar el empleo de estas ecuaciones, calculemos el error estándar de estimación para los datos de los promedios de las calificaciones y el CI de las tablas 7.1 y 7.2. Como antes, la variable Y representará el promedio de las calificaciones y la variable X representará el CI, y calculemos el error estándar de estimación para la predicción del promedio de las calificaciones cuando se conoce el CI. Según lo calculado en las tablas, $SC_X = 936.25$, $SC_Y = 7.022$, $\sum XY - (\sum X)(\sum Y)/N = 69.375$, y $N = 12$. Al sustituir estos valores en la ecuación para el error estándar de estimación al predecir Y dado X , obtenemos:

$$\begin{aligned} s_{Y|X} &= \sqrt{\frac{SC_Y - \frac{[\sum XY - (\sum X)(\sum Y)/N]^2}{SC_X}}{N - 2}} \\ &= \sqrt{\frac{7.022 - \frac{(69.375)^2}{936.25}}{12 - 2}} \\ &= \sqrt{0.188} = 0.43 \end{aligned}$$

Por lo tanto, el error estándar de estimación es 0.43. Esta medida se calcula sobre todos los datos Y . Para que tenga sentido, debemos suponer que la variabilidad de Y permanece constante cuando pasamos de un dato X a otro. Esto se conoce como la hipótesis de *homosedasticidad*. La figura 7.5(a) muestra un caso supuesto de homosedasticidad. La figura 7.5(b) ilustra un caso en que la hipótesis es violada. La hipótesis de homosedasti-



Tomadas de E. W. Minium, *Statistical Reasoning in Psychology and Education*. Derechos reservados © 1978 por John Wiley & Sons, Inc. Adaptado con autorización de John Wiley & Sons, Inc.

figura 7.5 Gráficas de dispersión que muestran la variabilidad de Y como función de X .

*Dividimos entre $N - 2$ debido a que el cálculo del error estándar de la estimación implica el ajuste de los datos a una recta. Para esto debemos estimar dos parámetros, la pendiente y la ordenada al origen, dejando a las desviaciones en torno de la recta con $N - 2$ grados de libertad. En el capítulo 13 analizaremos los grados de libertad.




figura 7.6 Distribución normal de los datos Y en torno de la recta de regresión.

cidad implica que si separamos los datos X en columnas, la variabilidad de Y no cambia de una columna a otra. Podemos ver que esto es cierto para la figura 7.5(a), pero no para la figura 7.5(b).

¿Qué significado tiene el error estándar de estimación? Está claro que cuantifica los errores de predicción. Mientras mayor sea su valor, menor confianza tendremos en la predicción. Recíprocamente, mientras menor sea su valor, más probable será que la predicción sea precisa. Podemos ser aún más cuantitativos. Supongamos que los puntos se distribuyen de manera normal en torno a la recta de regresión (figura 7.6). Si la hipótesis fuese válida y quisiéramos construir dos rectas paralelas a la línea de regresión, a las distancias de $\pm 1s_{Y|X}$, $\pm 2s_{Y|X}$, y $\pm 3s_{Y|X}$, veríamos que cerca del 68% de los datos se localizaría entre las rectas en $\pm 1s_{Y|X}$, aproximadamente el 95% de los datos estaría entre $\pm 2s_{Y|X}$, y, en forma aproximada, el 99% de los datos se encontraría entre $\pm 3s_{Y|X}$. Pa-




figura 7.7 Recta de regresión para los promedios de las calificaciones y el CI, con líneas paralelas $1s_{Y|X}$ arriba y abajo de la recta de regresión.

ra ilustrar este punto, en la figura 7.7 hemos trazado dos líneas punteadas, paralelas a la recta de regresión correspondiente a los promedios de las calificaciones y al CI, a una distancia de $\pm 1s_{Y|X}$. También hemos incluido los datos en la figura. De acuerdo con lo dicho, cerca del 68% de los datos deberá estar entre estas líneas. Como existen 12 puntos, esperaríamos que $0.68(12) = 8$ datos estuviesen dentro de las líneas, y esto sucede efectivamente en realidad. Esta coincidencia no siempre es tan buena, en particular cuando sólo se tienen 12 datos en la muestra. Cuando N aumenta, generalmente también la coincidencia aumenta.



CONSIDERACIONES AL UTILIZAR LA REGRESIÓN LINEAL PARA LA PREDICCIÓN

Los procedimientos que hemos descrito son adecuados para predecir datos, suponiendo que exista una relación lineal entre las variables X y Y . Si la relación es no lineal, la predicción no será muy precisa. Entonces, la primera suposición que deberemos tomar en cuenta para el uso exitoso de esta técnica es que la *relación entre X y Y sea lineal*. En segundo lugar, no estamos interesados, por lo general, en utilizar la recta de regresión para predecir las calificaciones de los individuos que estaban en el grupo empleado para calcular dicha línea de regresión. Después de todo, ¿para qué predecir sus calificaciones cuando ya las conocemos? Generalmente, se determina una recta de regresión para utilizarla con sujetos en los que alguna de las variables es desconocida. Por ejemplo, en el problema del CI y el promedio de las calificaciones, un empleado del departamento de inscripciones de una universidad podría utilizar esa recta de regresión para predecir los promedios de las calificaciones de los aspirantes, al conocer sus puntajes de CI. No tiene sentido predecir los promedios de las calificaciones de los 12 estudiantes cuyos datos fueron utilizados en el problema. Dicho empleado ya conoce esos promedios. Si vamos a




figura 7.8 Limitación de la predicción al rango de los datos básicos.

utilizar los datos de un grupo para predecir las calificaciones de otro, es importante que el grupo del cálculo básico sea representativo del grupo de predicción. Con frecuencia este requisito se controla mediante un muestreo aleatorio de la población objeto de la predicción, al utilizar la muestra para obtener la ecuación de regresión. El muestreo aleatorio se analiza en el capítulo 8. Por último, la ecuación de regresión lineal se utiliza de manera apropiada, sólo para el rango de la variable en la cual se basa. Por ejemplo, al predecir el promedio de las calificaciones mediante el CI, debemos limitar nuestras predicciones a datos de CI que varíen de 110 a 138. Como no tenemos datos fuera de este rango, no sabemos si la relación sigue siendo lineal para valores más extremos del CI.

Para ilustrar este punto, consideremos la figura 7.8, donde hemos ampliado la recta de regresión a fin de incluir los valores de CI hasta 165. En la universidad donde se tomó la muestra de los datos, el promedio máximo de calificaciones fue de 4.0. Si empleáramos la recta de regresión extendida para predecir el promedio de calificaciones que corresponde a un CI de 165, tendríamos un promedio de 5.2, un valor que obviamente es incorrecto. La predicción para un CI arriba de 165 sería todavía peor. Al observar la figura 7.8, podemos apreciar que cuando la relación se extiende más allá de un CI de 138, no puede extenderse también más allá de un CI de 149 aproximadamente (el valor del CI donde la recta de regresión alcanza un promedio de calificaciones de 4.0). Por supuesto, no hay razón alguna para creer que exista una relación más allá del punto básico de $CI = 138$, y por ese motivo no debemos hacer predicciones mediante esta relación para valores de CI mayores que 138.



RELACIÓN ENTRE LAS CONSTANTES DE REGRESIÓN Y LA r DE PEARSON

Aunque no hemos presentado este aspecto de la r de Pearson antes, se puede demostrar que la r de Pearson es la pendiente de la recta de regresión por mínimos cuadrados al graficar los datos como puntajes z . Por ejemplo, utilicemos los datos de la tabla 6.3 correspondientes al peso y el costo de seis bolsas de naranjas. Para comodidad del lector, hemos reproducido los datos en la tabla 7.4. La figura 7.9(a) muestra la gráfica de dispersión y la recta de regresión por mínimos cuadrados para estos datos en bruto. Como ésta es una relación lineal perfecta, $r = 1.00$. La figura 7.9(b) muestra la gráfica de dispersión para estas parejas de puntajes z y la recta de regresión por mínimos cuadrados para estos puntajes z . La pendiente de la recta de regresión para los datos en bruto es b y la pendiente de la recta de regresión para los puntajes z es r . Observe que la pendiente de esta última recta de regresión es 1.00, como debe ser, ya que $r = 1.00$.

tabla 7.4 Costo y peso en libras de seis bolsas de naranjas

Bolsa	Peso (libras) X	Costo (\$) Y	z_X	z_Y
A	2.25	0.75	-1.34	-1.34
B	3.00	1.00	-0.80	-0.80
C	3.75	1.25	-0.27	-0.27
D	4.50	1.50	0.27	0.27
E	5.25	1.75	0.80	0.80
F	6.00	2.00	1.34	1.34




figura 7.9 Relación entre b y r .

Como la r de Pearson en una pendiente, se relaciona con b_Y y b_X . Se puede demostrar en forma algebraica que:

$$b_Y = r \frac{s_Y}{s_X}$$

y también

$$b_X = r \frac{s_X}{s_Y}$$

Estas ecuaciones son útiles si ya hemos calculado r , s_X y s_Y y queremos determinar la recta de regresión por mínimos cuadrados. Por ejemplo, en el problema del CI y el promedio de las calificaciones, $r = 0.8556$, $s_Y = 0.7990$ y $s_X = 9.2257$. Suponga que queremos determinar b_Y y a_Y cuando ya hemos calculado r , s_Y y s_X . La forma más sencilla de hacer consiste en emplear la ecuación

$$b_Y = r \frac{s_Y}{s_X} = 0.8556 \left(\frac{0.7990}{9.2257} \right) = 0.074$$

Observe que éste es el mismo valor al que llegamos anteriormente, en la página 139. Una vez determinado b_Y , calculamos a_Y de la manera usual.



REGRESIÓN MÚLTIPLE Y CORRELACIÓN MÚLTIPLE

Hasta ahora hemos analizado la regresión y la correlación mediante ejemplos con sólo dos variables. Cuando analizamos la relación entre el promedio de las calificaciones y el CI, determinamos que $r = 0.856$ y que la ecuación de la recta de regresión para predecir el promedio a partir del CI era:

$$Y' = 0.74X - 7.006$$

donde Y' = predicción del promedio de las calificaciones
 X = el dato del CI

La regresión múltiple es una extensión de la regresión simple para incluir las situaciones en que hay dos o más variables de predicción. Por ejemplo, suponga que tenemos datos de los 12 estudiantes, que incluyen una segunda variable de predicción llamada “tiempo de estudio”, así como los datos originales del promedio de las calificaciones y el CI. Los datos de estas tres variables aparecen en las columnas 2, 3 y 4 de la tabla 7.5. Ahora podemos obtener una ecuación de regresión para predecir el promedio de las calificaciones mediante las dos variables de predicción, el CI y el tiempo de estudio. La forma general de la ecuación de regresión múltiple para las dos variables de predicción es:

donde

- Y' = predicción del valor de Y
- b_1 = coeficiente de la primera variable de predicción
- X_1 = primera variable de predicción
- b = coeficiente de la segunda variable de predicción
- X_2 = segunda variable de predicción
- a = una constante de predicción

[illegible][illegible]

Esta ecuación es muy similar a la que fue utilizada en el caso de la regresión simple, excepto que hemos agregado otra variable de predicción y su coeficiente. Como antes, los valores del coeficiente y la constante se determinan de acuerdo con el criterio de mínimos cuadrados, donde $\sum (Y - Y')^2$ alcanza un mínimo. Sin embargo, esta vez las matemáticas son complicadas y los cálculos reales casi siempre se realizan en una computadora dotada de un software estadístico. Para los datos de nuestro ejemplo, la ecuación de regresión múltiple que minimiza los errores en Y está dada por:

$$Y' = 0.049X_1 + 0.118X_2 - 5.249$$

donde Y' = predicción del valor del promedio de las calificaciones

$$b_1 = 0.049$$

X_1 = puntaje del CI

$$b = 0.118$$

X_2 = dato del tiempo de estudio

$$a = 5.249$$

Para determinar si la precisión de la predicción aumenta al utilizar la ecuación de regresión múltiple, en la quinta columna de la tabla 7.5 colocamos las predicciones de los promedios de calificaciones al emplear sólo el CI para la predicción, y en la sexta columna aparecen las predicciones de dichos promedios al utilizar el CI y el tiempo de estudio como variable de predicción, y los errores de predicción respectivos se han presentado en las columnas 7 y 8 respectivamente. También graficamos en la figura 7.10(a) el valor Y real y las dos predicciones de los valores de Y' para cada estudiante. Ordenamos a los alumnos de izquierda a derecha sobre el eje X , de acuerdo con la mayor precisión de la predicción resultante para cada uno, al utilizar la ecuación de regresión múltiple. En la figura 7.10(b) graficamos el porcentaje de mejoría en la precisión de la predicción para cada estudiante, que resulta del hecho de utilizar el CI + el tiempo de estudio, en vez de usar sólo el CI. Al ver la tabla 7.5 y la figura 7.10, resulta claro que el uso de la ecuación de regresión múltiple ha mejorado en gran medida la precisión general de la predicción. Por ejemplo, la precisión de la predicción aumentó en todos los estudiantes, excepto en la del número 11, y para el estudiante número 3 la precisión aumentó en casi 40%. En la parte inferior de la tabla 7.5 mostramos también el valor de $\sum (Y - Y')^2$ para cada recta de regresión. Al agregar la segunda variable de predicción, el error de predicción total al cuadrado se redujo de 1.88 a 0.63, una mejora de más de 66 por ciento.

Como en este ejemplo aumentó la precisión de la predicción al utilizar dos variables en vez de una, esto implica que la proporción de la varianza de Y explicada ha aumentado también. Al tratar de determinar esta proporción, usted podría sentir la tentación de ampliar el concepto de r^2 de nuestro análisis anterior de la correlación, a calcular r^2 entre el promedio de calificaciones y cada variable, y luego sumar simplemente los valores resultantes. La tabla 7.6 muestra una matriz de correlación r de Pearson que corresponde al promedio de calificaciones, el CI y el tiempo de estudio. Si siguiéramos este procedimiento, la proporción de varianza explicada sería mayor que 1.00 $[(0.856)^2 + (0.829)^2 = 1.42]$, lo cual es imposible. No es factible explicar más del 100% de la variabilidad. El error se produce debido a que hay un traslape en la varianza explicada entre el CI y el tiempo de estudio. Los alumnos con mayor CI tienden a estudiar más tiempo. Por lo tanto, parte de la varianza en el promedio de las calificaciones explicada por el CI también puede explicarse por medio del tiempo de estudio. Para corregir esta situación, debemos tomar en cuenta la correlación entre el CI y el tiempo de estudio.

La ecuación correcta para el cálculo de la proporción de la varianza explicada, cuando existen dos variables de predicción está dada por:

$$R^2 = \frac{r_{YX_1}^2 + r_{YX_2}^2 - 2r_{YX_1}r_{YX_2}r_{X_1X_2}}{1 - r_{X_1X_2}^2}$$





figura 7.10 Comparación de la precisión de las predicciones utilizando una o dos variables de predicción.

tabla 7.6 Matriz de correlación de Pearson entre el CI, el tiempo de estudio y el promedio de las calificaciones

	CI (X_1)	Tiempo de estudio (X_2)	Promedio de las calificaciones (Y)
CI (X_1)	1.000		
Tiempo de estudio (X_2)	0.560	1.000	
Promedio de las calificaciones (Y)	0.856	0.829	1.000

donde R^2 = coeficiente múltiple de determinación

r_{YX_1} = correlación entre Y y la variable de predicción X_1

r_{YX_2} = correlación entre Y y la variable de predicción X_2

$r_{X_1X_2}$ = correlación entre las variables de predicción X_1 y X_2

A menudo R^2 recibe también el nombre de correlación múltiple cuadrada. Tomando como base los datos del presente estudio, r_{YX_1} = la correlación entre el promedio de las calificaciones y el CI = 0.856, r_{YX_2} = la correlación entre Y y el tiempo de estudio = 0.829, y $r_{X_1X_2}$ = la correlación entre el CI y el tiempo de estudio = 0.560. Para estos datos,

$$R^2 = \frac{(0.856)^2 + (0.829)^2 - 2(0.856)(0.829)(0.560)}{1 - (0.560)^2}$$

$$= 0.910$$

Así pues, la proporción de varianza explicada ha aumentado de 0.73 a 0.91 por el hecho de utilizar el CI y el tiempo de estudio.

Por supuesto, el mero hecho de agregar otra variable de predicción no incrementa necesariamente la precisión de la predicción o la cantidad de varianza explicada. Esto depende de la fuerza de la relación entre la variable objeto de la predicción y la variable de predicción adicional, y también de la fuerza de la relación entre las propias variables de predicción. Por ejemplo, observemos lo que le sucede a R^2 cuando $r_{X_1X_2} = 0$. Este tema es analizado con mayor detalle en textos más avanzados.