

criptiva, nuestra preocupación principal era lograr la presentación y descripción de los conjuntos de datos de la manera más significativa y eficaz. En la estadística inferencial vamos más allá de la mera descripción de los datos, ya que un objetivo básico es el uso de los datos provenientes de una muestra para hacer una afirmación acerca de una característica de la población. Se hacen dos tipos de afirmaciones: una tiene que ver con la actividad conocida como *prueba de hipótesis* y la otra con la *estimación de parámetros*.

En la prueba de hipótesis, el investigador recolecta datos de un experimento sobre el conjunto de sujetos de una muestra, en un intento de validar cierta hipótesis relativa a una población. Por ejemplo, suponga que una psicóloga dedicada a la educación cree que un nuevo método para enseñar la asignatura de matemáticas a los niños de tercer grado, en su distrito escolar (población), es mejor que la forma usual de enseñanza. En el experimento, ella toma dos muestras de los alumnos de tercer grado, a una de las cuales se le imparte el nuevo método de enseñanza y a la otra el método usual. Cada grupo presenta el mismo examen final. Al hacer esta prueba, la psicóloga no se conforma con sólo informar que la media del grupo que recibió el nuevo método fue mayor que la del otro grupo. Ella quiere hacer una afirmación como: “La mejoría observada en las calificaciones del examen final fue resultado del nuevo método de enseñanza y no del azar. Además, dicha mejoría no sólo se aplicaría a la muestra particular sometida a prueba, sino que aparecería en toda la población de estudiantes de tercer grado si se les enseñase con el nuevo método”. Las técnicas utilizadas en estadística inferencial permiten hacer afirmaciones de este tipo.

En los experimentos para la estimación de parámetros, el investigador está interesado en determinar la magnitud de una característica de la población. Por ejemplo, a un economista podría importarle la determinación de la cantidad mensual promedio de dinero gastada el año pasado en alimentos por los estudiantes de bachillerato. Con los datos de una muestra y las técnicas de la estadística inferencial, él puede estimar la cantidad media que gasta la población. El economista podría concluir con una afirmación como la siguiente: “Existe una probabilidad de 0.95 de que el intervalo \$250-\$300 contenga la media de la población”.

Los temas de *muestreo aleatorio* y de *probabilidad* son fundamentales para la metodología de la estadística inferencial. En la siguiente sección estudiaremos el muestreo aleatorio. El resto del capítulo tratará sobre los principios básicos de la probabilidad.



MUESTREO ALEATORIO

Para generalizar de manera válida, a partir de una muestra a toda la población, tanto en los experimentos de prueba de hipótesis como en los de estimación de parámetros, la muestra no puede ser *cualquier subconjunto* de la población. Es crucial que sea una muestra *aleatoria*.

definición ■ Una **muestra aleatoria** es elegida de la población mediante un proceso con el cual se asegura que 1) cada posible muestra de un tamaño dado tenga la misma probabilidad de ser elegida y 2) todos los miembros de la población tengan la misma probabilidad de ser seleccionados en la muestra.*

* Véase la nota 8.1 de la p. 196.

Para ilustrar esto, consideremos una situación en la que tenemos una población con los datos 2, 3, 4, 5 y 6, y queremos extraer de manera aleatoria una muestra de tamaño 2 a partir de dicha población. Observe que, por lo general, una población tendría más datos. La hemos restringido a cinco elementos para facilitar la comprensión de lo que queremos poner de manifiesto. Suponga usted que estamos realizando un muestreo de esta población y que tomamos un dato a la vez, para luego volver a colocarlo con el resto de dicha población antes de extraer otro. Esto se llama *muestreo con reemplazo* y será analizado posteriormente en este capítulo. A continuación presentamos todas las muestras de tamaño 2 que podemos obtener de la población aplicando este método de muestreo:

2, 2	3, 2	4, 2	5, 2	6, 2
2, 3	3, 3	4, 3	5, 3	6, 3
2, 4	3, 4	4, 4	5, 4	6, 4
2, 5	3, 5	4, 5	5, 5	6, 5
2, 6	3, 6	4, 6	5, 6	6, 6

Son 25 muestras de tamaño 2 las que podemos obtener al realizar el muestreo de un elemento a la vez con reemplazo. Para realizar un muestreo aleatorio, el proceso debe ser tal que 1) las 25 muestras posibles y 2) todos los datos de la población (2, 3, 4, 5 y 6) tengan la misma probabilidad de ser seleccionados en la muestra.

La muestra debe ser aleatoria por dos razones. La primera es que para que se pueda generalizar a toda la población una característica observada en una muestra, es necesario aplicar las leyes de la probabilidad. Si la muestra no ha sido obtenida mediante un procedimiento con el cual se garantice que cada muestra posible del tamaño elegido tenga la misma posibilidad de ser escogida, no podremos aplicar las leyes de probabilidad a esa muestra. La importancia que tiene para la inferencia estadística este aspecto de aleatoriedad y de probabilidad se podrá apreciar claramente cuando hayamos analizado los capítulos referentes a la prueba de hipótesis y a las distribuciones muestrales (véanse los capítulos 10 y 12 respectivamente).

La segunda razón para la utilización del muestreo aleatorio consiste en que, para asegurar la generalización de una característica de la muestra a toda la población, es necesario que dicha muestra sea representativa de la población en cuestión. Una forma de lograr la representatividad consiste en elegir la muestra por medio de un proceso que garantice que todos los miembros de la población tengan la misma posibilidad de ser escogidos. Por lo tanto, el hecho de requerir que una muestra sea aleatoria permite aplicar las leyes de probabilidad sobre la muestra misma y, por ende, que ésta sea representativa de la población.

Es tentador pensar que podemos lograr la representatividad de una muestra utilizando métodos distintos al del muestreo aleatorio. Sin embargo, con mucha frecuencia el procedimiento utilizado produce una muestra sesgada (no representativa). Un ejemplo de esto es la famosa encuesta presidencial del *Literary Digest* de 1936, la cual predijo una victoria aplastante de Landon (57 a 43%). De hecho, Roosevelt ganó con 62% de los votos. La predicción del *Literary Digest* resultó ser un error garrafal. ¿Por qué? Un análisis posterior reveló que el error se debió a que la muestra no era representativa de la población votante, sino que era una muestra *sesgada*. Los individuos fueron elegidos de fuentes tales como el directorio telefónico, registros de clubes y listas de propietarios de automóviles. Esos registros excluyeron de manera sistemática a las personas pobres, quienes tal vez no tenían teléfonos ni automóviles. Y ocurrió que los pobres votaron en forma aplastante a favor de Roosevelt. Aunque otros métodos de muestreo pudieran producir una muestra representativa, éstos no serían útiles para la inferencia, pues no podríamos aplicar las leyes de la probabilidad necesarias para generalizar de la muestra a toda la población.

Técnicas para el muestreo aleatorio

Un estudio profundo de las formas con las cuales se generan las muestras aleatorias está más allá del objetivo de este libro. Este tema puede ser complejo, en particular al trabajar con encuestas. Sin embargo, presentaremos algunas técnicas de uso común, junto con varias situaciones sencillas, de manera que usted pueda darse una idea de lo que esto implica. Suponga que tenemos una población de 100 personas y queremos obtener una muestra aleatoria de 20 personas para un experimento. Una forma de hacer esto sería enumerar a los individuos de la población del 1 al 100, luego tomar 100 pedazos de papel y numerarlos, colocar los papeles en un sombrero para revolverlos y después elegir uno. Volveríamos entonces a mezclar los papelitos para elegir otro. Luego, continuaríamos este proceso hasta haber elegido 20 pedazos de papel. Los números escritos en los pedazos de papel identificarían a los individuos que compondrían la muestra. En este método de muestreo aleatorio, es crucial que la población (los trozos de papel) esté bien “revuelta” para garantizar la aleatoriedad.

Un procedimiento común para producir muestras aleatorias consiste en utilizar una tabla de números aleatorios, como la que hemos incluido en la tabla J del apéndice D. Este tipo de tablas se hace, por lo regular, mediante un programa de computadora, el cual garantiza que todos los dígitos (0-9) tengan la misma posibilidad de ser elegidos cada vez que se imprima un dígito.

La tabla se puede emplear como una sucesión de dígitos simples consecutivos, números de dos dígitos, números de tres dígitos, etc. Por ejemplo, en la tabla J, página 546, si comenzamos en el primer renglón y nos movemos en dirección horizontal por la página, el orden aleatorio de los dígitos simples sería 3, 2, 9, 4, 2, Si quisiéramos utilizar números de dos dígitos, entonces el orden aleatorio sería 32, 94, 29, 54, 16,

Como los dígitos de la tabla son aleatorios, se pueden utilizar vertical u horizontalmente en ambas direcciones. La dirección que se va a usar debe especificarse antes de emplear la tabla; para manejarla de manera adecuada, hay que comenzar en forma aleatoria. Una posibilidad de lograr esto es hacer tarjetas con números de renglón y de columna, colocarlas en una caja, revolverlas y luego elegir un número para el renglón y otro para la columna. La intersección del renglón y la columna sería la posición del primer número aleatorio. Los demás números serían localizados al desplazarse desde el primer número, en la dirección convenida antes de entrar a la tabla. Por ejemplo, suponga que queremos formar una muestra aleatoria de 3 sujetos de una población de 10 sujetos.* Para este ejemplo hemos decidido movernos sobre la tabla en dirección horizontal, a la derecha. Para elegir la muestra, primero asignamos a cada individuo de la población un número del 0 al 9. Luego entramos en la tabla de manera aleatoria para localizar el primer número. Suponga que el dato es el primer número del séptimo renglón, que es igual a 3. Este número designa al primer sujeto de la muestra. Como hemos decidido movernos sobre la tabla hacia la derecha, los dos números siguientes son 5 y 6. De esta manera, los individuos que portan los números 5 y 6 completarían la muestra.

Resolvamos ahora un problema en el cual la población tiene más individuos. Con propósitos ilustrativos, supondremos que se desea extraer una muestra aleatoria de 15 sujetos, de una población de 100. Para variar las cosas un poco, para este ejercicio decidimos desplazarnos verticalmente sobre la tabla, hacia abajo, en lugar de hacerlo en dirección horizontal, hacia la derecha. Como antes, necesitamos asignar una cifra a cada miembro de la población. Esta vez, los números asignados serán del 00 al 99 en vez de 0

*Por supuesto, en los experimentos reales, el número de elementos de la población es mucho mayor que 10. Utilizamos 10 en el primer ejemplo para ayudar a comprender la forma correcta de emplear la tabla.

a 9. De nuevo, entramos a la tabla de manera aleatoria. Esta vez suponemos que el primer dato o primer número de dos dígitos aparece en la intersección de la columna 3 con el renglón 12. El guarismo de dos dígitos localizado en esa intersección es 70. Por lo tanto, el primer sujeto de la muestra es el individuo a quien le corresponde el número 70. Para localizar al siguiente sujeto de la muestra, bajamos verticalmente en la tabla a partir del 70. Así, el segundo sujeto de la muestra sería el individuo que tiene el número 33. Continuaríamos este procedimiento hasta que hayamos seleccionado 15 sujetos. El conjunto completo de números que representan a los sujetos de la muestra sería: 70, 33, 82, 22, 96, 35, 14, 12, 13, 59, 97, 37, 54, 42 y 89. Al obtener este conjunto de números, el 82 apareció dos veces en la tabla. Como el mismo individuo no puede estar en la muestra más de una vez, no incluimos el número repetido.

Muestreo con o sin reemplazo

Hasta ahora hemos definido una muestra aleatoria, analizamos la importancia del muestreo aleatorio y presentamos algunas técnicas para producir muestras aleatorias. Para completar nuestro estudio, debemos distinguir entre el “muestreo con reemplazo” y el “muestreo sin reemplazo”. Para ilustrar la diferencia entre estos dos métodos de muestreo, suponga que queremos formar una muestra de dos datos provenientes de una población compuesta por los números 4, 5, 8 y 10. Una manera de hacer esto consistiría en extraer un dato de la población, registrar su valor, y reintegrarlo a la población antes de extraer el segundo elemento. Así, el primer dato podría ser elegido de nuevo en la segunda extracción. Este método se llama *muestreo con reemplazo*. Una segunda alternativa consistiría en extraer al azar un dato de la población y no reemplazarlo antes de seleccionar el segundo. De esta manera, cualquier número proveniente de la población podría aparecer en la muestra solamente una vez. A este método se le llama *muestreo sin reemplazo*.

- definiciones** ■ *El muestreo con reemplazo se define como un método en el cual cada miembro de la población elegida para la muestra se reintegra a la población antes de seleccionar al siguiente miembro.*
- *El muestreo sin reemplazo se define como un método en el cual los miembros de la muestra no son reintegrados a la población antes de seleccionar a los miembros subsecuentes.*

Al elegir a los sujetos que participan en un experimento, hay que utilizar el muestreo sin reemplazo, pues el mismo individuo no puede estar en la muestra más de una vez. Es probable que usted reconozca éste como el método utilizado en la sección anterior. El muestreo con reemplazo constituye la base matemática para muchas de las pruebas de inferencia que analizaremos posteriormente. A pesar de que los dos métodos no producen resultados idénticos, cuando el tamaño de la muestra es pequeño en comparación con el tamaño de la población, las diferencias son insignificantes y las técnicas “con reemplazo” resultan mucho más fáciles de utilizar cuando se desea proporcionar la base matemática para la inferencia. Pasemos ahora al tema de la probabilidad.